4.2 混合式P2P网络（第一代）

4.2.1 集中目录模式Napster

- C/S集中目录查询，P2P下载
  - Peers连接到能提供共享内容的中心目录上，匹配请求与索引
  - 文件直接在两个Peers间交换
- 需要一些可管理的设施
  - 目录服务器：记载群组所有参加者的信息
- 限制了规模的扩大：
  - 大量用户增加—>大量请求->大服务器->存储器
- 然Napster经验表明：
  - 除开法律问题外，该模式还很有效和强大
  - 1999.12被多家唱片公司起诉、并败诉

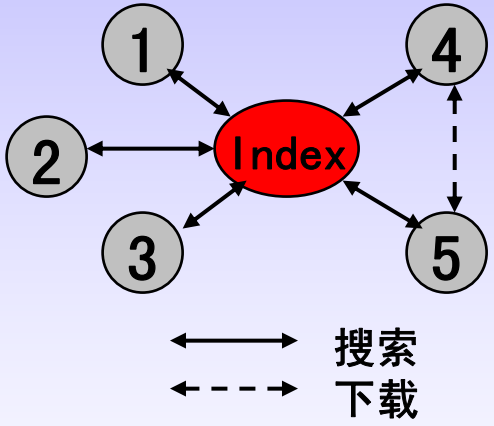

P2P网络先驱 Napster

- 1999，18岁Shawn Fanning开发
  - 让音乐迷交流MP3文件
  - 服务器只提供索引，无任何歌曲，MP3文件在Peers自己的硬盘上
- 第一个在互联网上不经过服务器直接交换文件的应用体系
  - 发布半年后，吸引到5000--6100万注册用户
  - 然其初衷只是想在Boston的东北大学校园与Virginia的朋友共享MP3歌曲

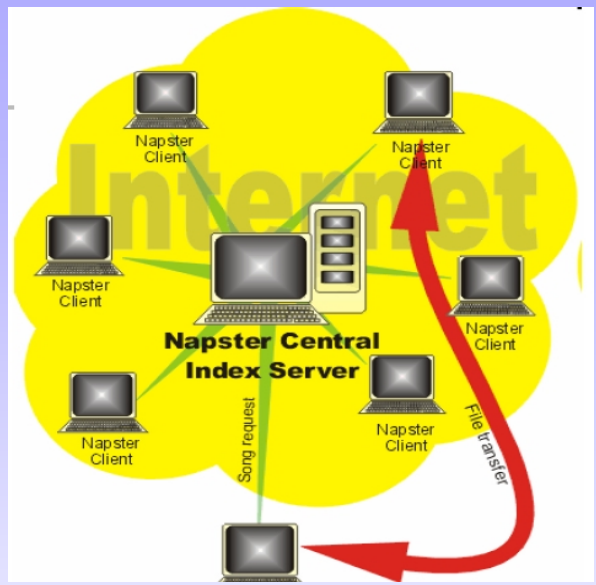

Napster结构

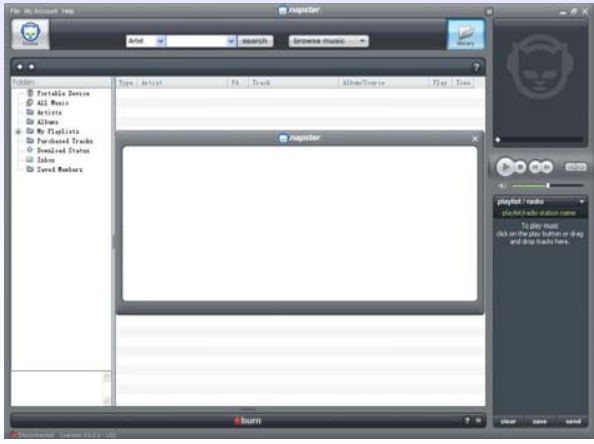
Napster界面

Napster: Example

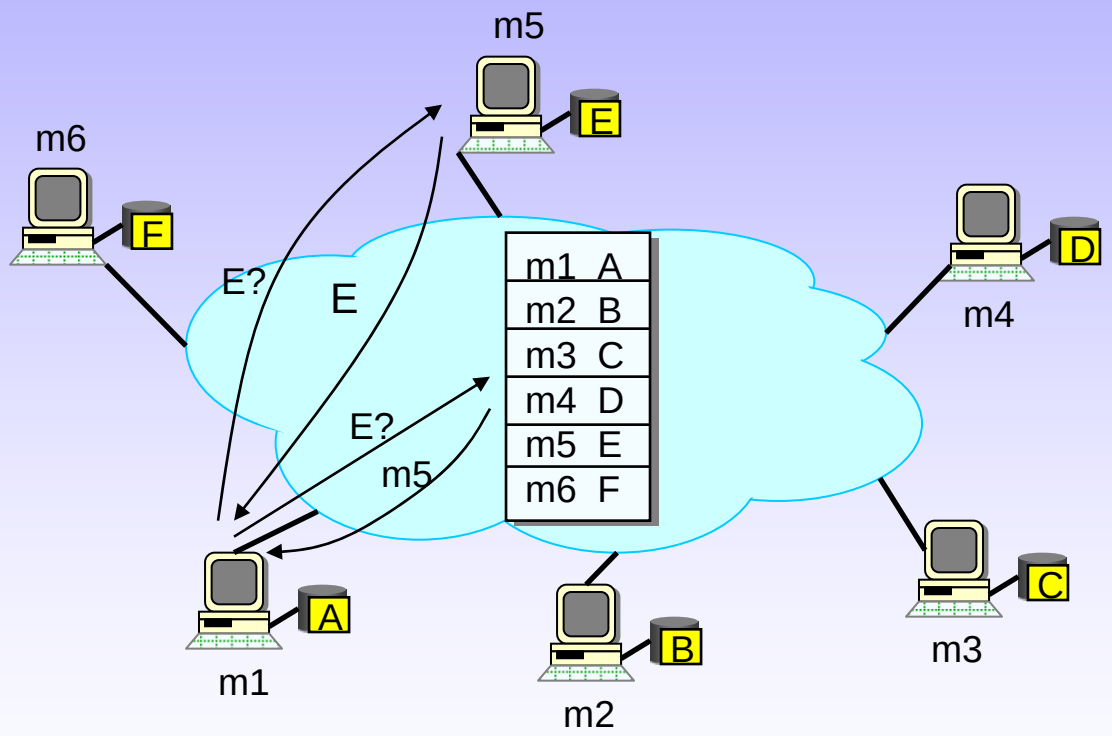

Napster原理

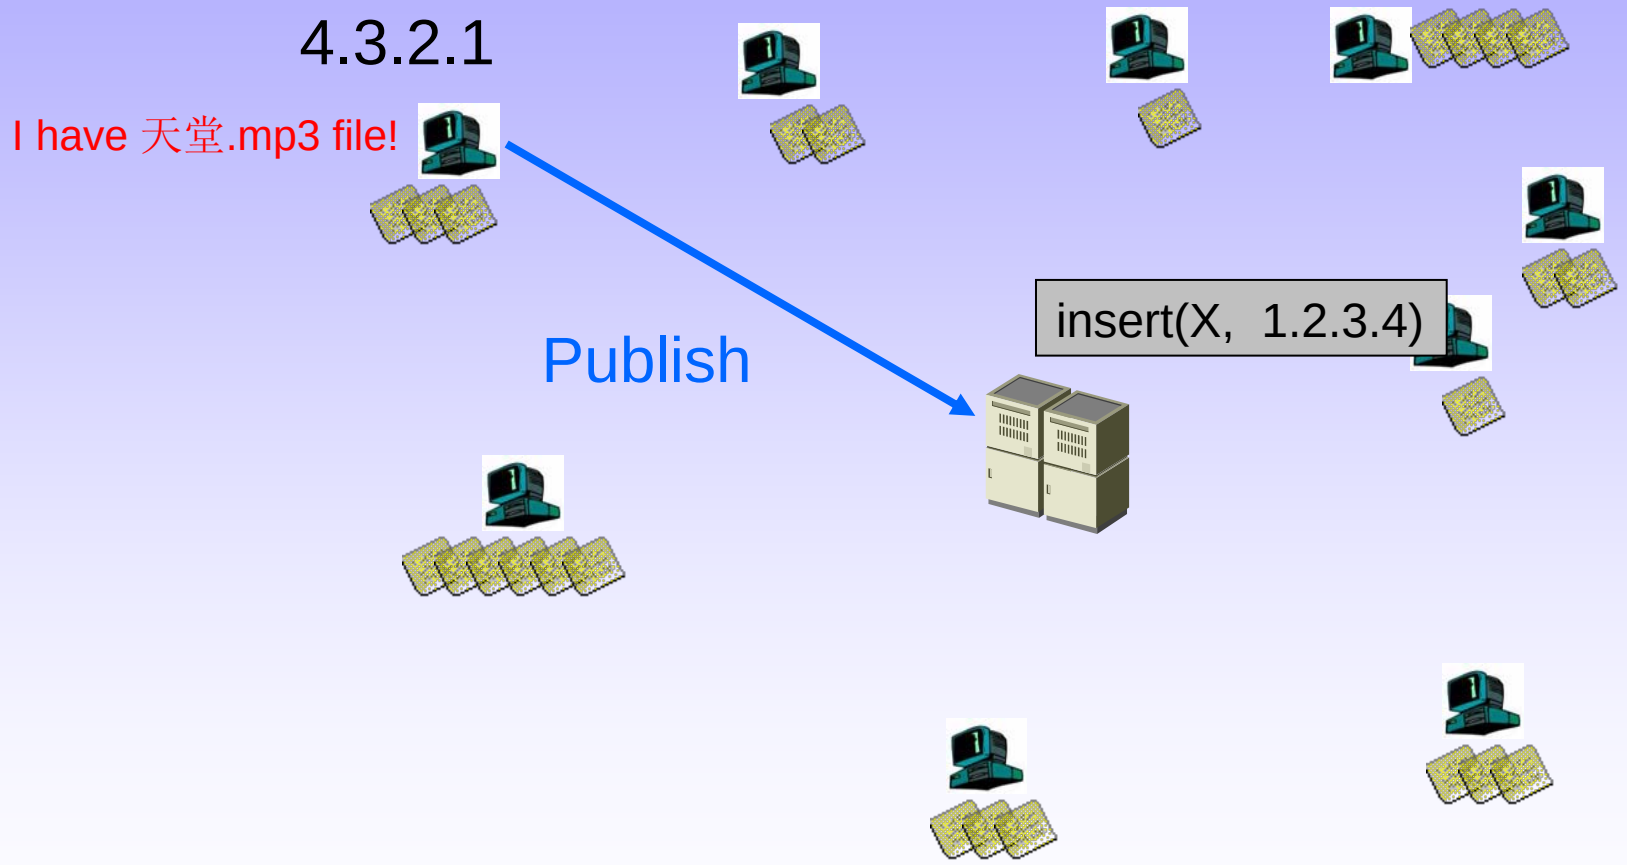

Napster原理

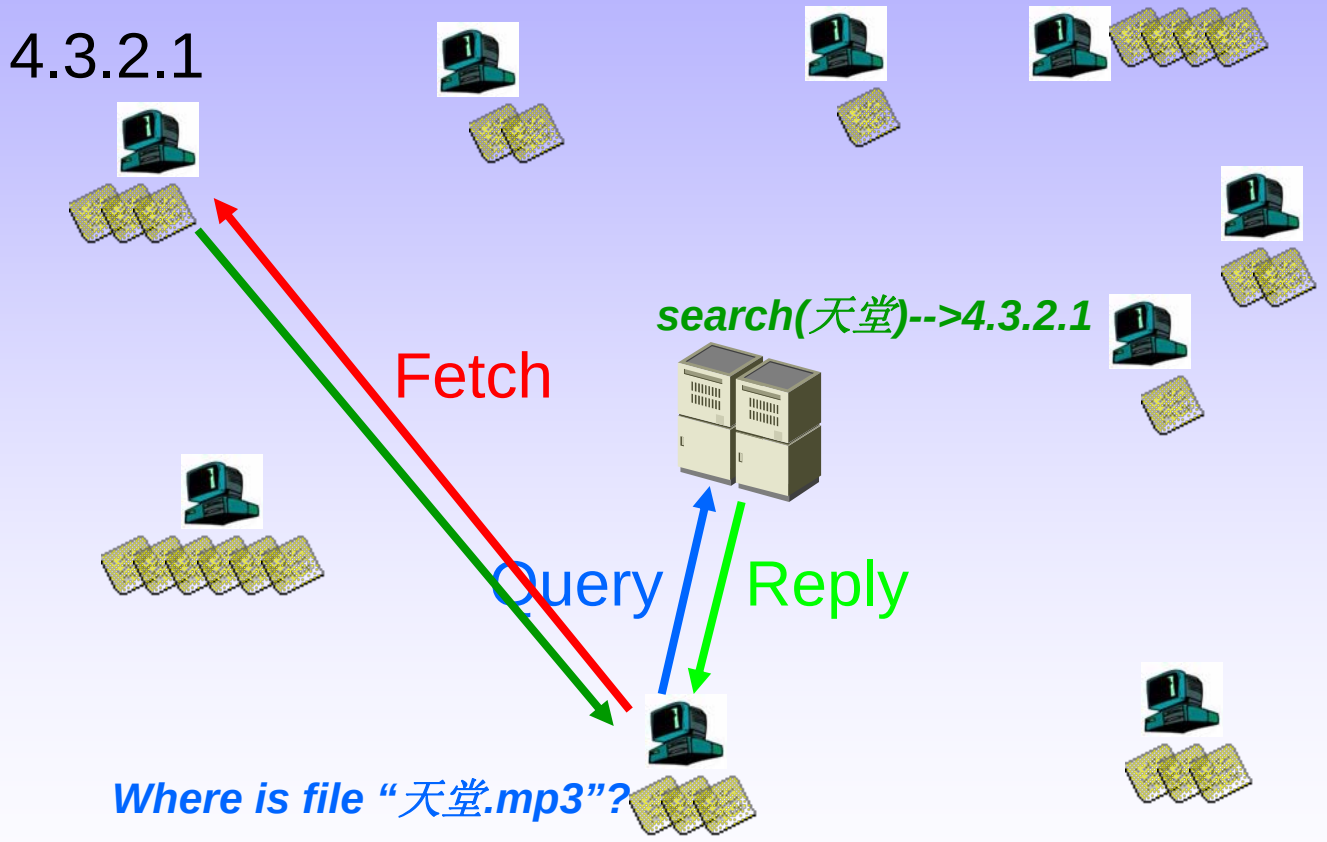

Napster官司及缺点

- 官司
  - 1999.12.7,美国唱片协会代表7大唱片公司指控Napster侵犯音乐版权，要求法院关闭该公司并赔偿1亿美元；
  - 2000.2月，旧金山第九巡回上诉法院的3名法官裁决，认为Napster一直知道并纵容用户侵权，但没有应要求立即关闭Napster，而是把初判送到低一级地方法院
  - … …
  - 2001.7.12,法官Patel命令Napster继续关闭直到它可以证明能够有效阻止对版权文件的使用。
- “魔鬼”钻出了“魔瓶”：
  - Napster背后的技术和思想给互联网带来的极大影响，而魔瓶已经打破，唱片经销方式被彻底改变，并带来互联网新的long Tail 现象
- Napster的缺点：
  - C/S的单点故障、系统瓶颈、可扩展性低
  - 未考虑不同用户的能力差异、无鼓励机制
  - 版权问题

4.2.2 分片优化的BitTorrent

- BT故事
  - 2002.10，穷困潦倒的Bram Cohen发明BT，免费软件企业家John Gilmore帮助他解决了部分生活费
  - 2003初，在Internet2(连接200多所美国大学的Abilene主干)用BT发行一个新版的Linux和日本卡通，速度比ADSL快3500多倍，10月流量超过Internet2流量的10%
    - 但2003.9，Bram Cohen还在用一张信用卡的免费透支来偿还另一张的账单
  - Valve软件公司的董事Gabe Newell正在游戏分发网络，在Seattle给它一个职位
  - BT既指一个混合式P2P网络，也指其对应的协议及支持该协议的应用软件--BitTorrent/BitComet/BitSpirit/ FlashBT
  - 中国BT网站和搜索引擎：BT@China联盟/冰鱼BT站/影视帝国/教育网总站5Q/好123网址之家

BitTorrent原理

- 构成（4大部分）
  - BT网站+.torrent文件服务器+Tracker+BT用户
- 各部功能
  - Seeds：拥有整个文件的用户
  - BT网站提供BT种子文件.torrent
    - 种子文件的一个子集，用户在其返回.torrent中再选择种子文件
    - 内含.torrent上传日期，文件名，大小，种子数，在tracker注册的下载用户数，软件运行的OS，上传.torrent文件的用户，大相关网页的连接 + Tracker的位置，所要下载文件的Hash值
  - Tracker：用户信息维护者
    - 跟踪所有下载同一文件的用户，构成1独立子网，实时分发所有用户信息给每个Peer
    - 和用户之间用HTTP协议交互。
    - 用户告诉要下载的文件、自己的端口号等
    - Tracker告诉下载同样文件的其它用户信息
    - 收集和统计上传和下载的相关信息

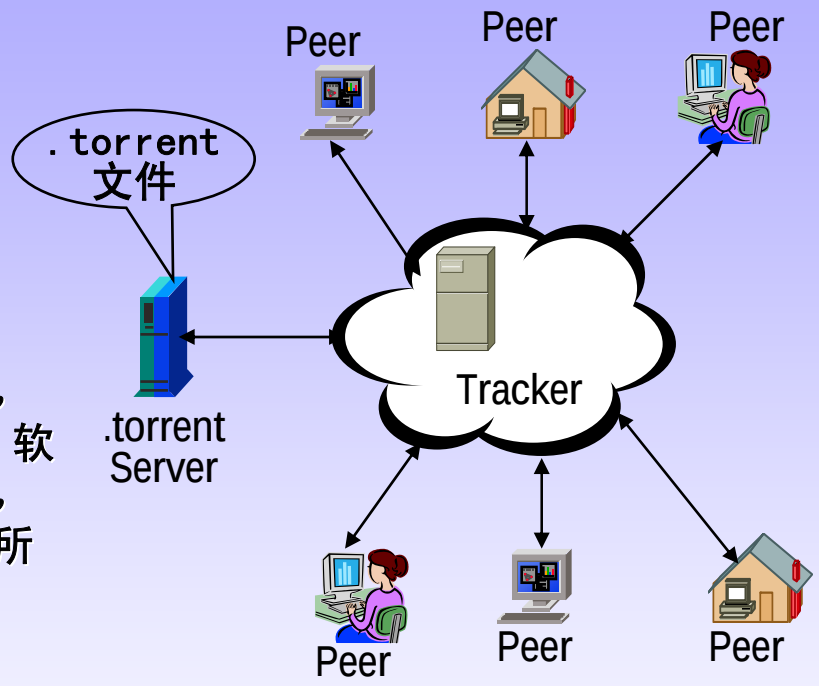

BitTorrent 结构

我为人人，人人为我

- 上载
  - 某Peer想要共享文件或目录，则为该文件或目录生成一“种子”文件（或元信息：含该文件或目录名＋用户的 URL信息）
  - 然后把该“种子”上传到BT服务器上（或Tracker）
- 下载
  - 需下载的Peer到Tracker上找到所需种子
  - 根据种子信息进行下载

1. 用户通过BT网站搜索文件，得到.torrent文件列表
2. 用户选择列表中的一项或多项
   - 每个被选.torrent文件会启动一项下载任务，
   - 通常.torrent会指向该文件对应的Tracker，
   - 而Tracker会把一部分用户信息给请求者
3. 用户根据Tracker用户信息
   - 与其它用户建立连接
   - 从它们下载文件分片，也提供分片
4. 高速高效
   - 并不总是和最初邻居交换分片，而是每隔一段时间从Tracker获得新的邻居
   - 采用“阻塞算法”主动停止那些对自己无贡献的邻居，寻求更好的邻居

BT 的结构

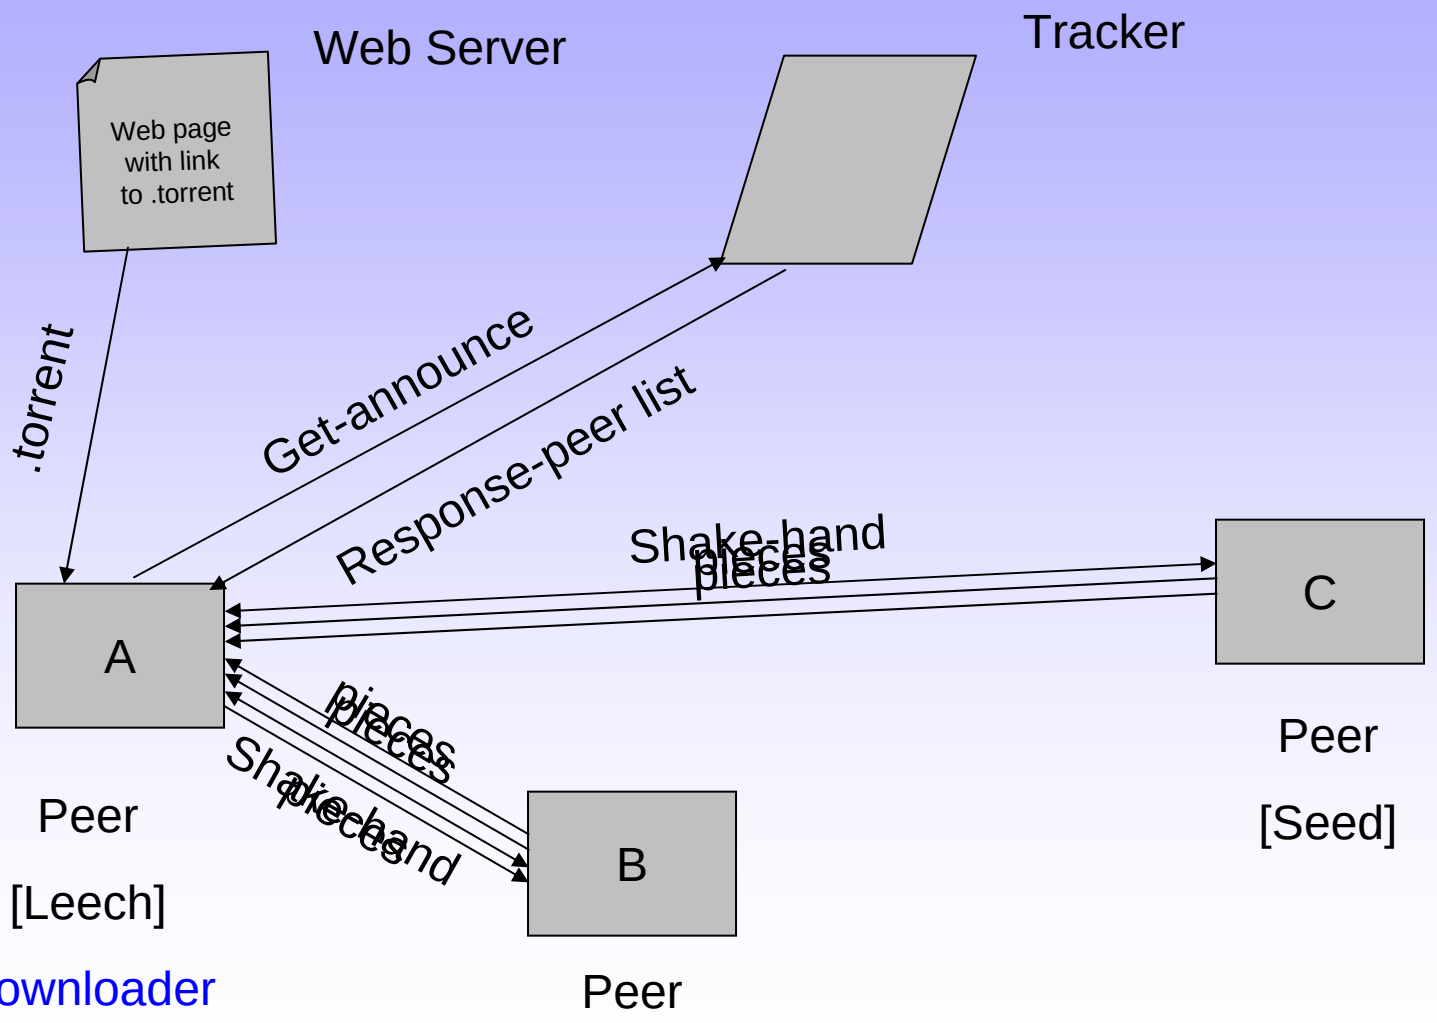
Web Server
Tracker
Web page with link to .torrent
.torrent
Get-announce
Response-peer list
Shake-hand
pieces
A
C
Peer
[Leech]
Peer
[Seed]
Downloader
B
Peer
[Leech]

BitTorrent的分片与分发

- 分割分片
  - BT把文件分割成相同大小的块，典型256KB，为流水在分为16KB的子分片
  - 用SHA-1对每个分片或子分片生成**校验值或文件块ID**;保存在.torrent中，
  - 只有在验证其唯一性完整性后才通知其它peer自己拥有该片
- 流水分发
  - 在TCP之上，可流水地同时发送多个请求，通常5个，以避免两个分片间的延迟
- 分片选择的阶段规则
  - **最初：随机选择**一个分片
  - **分片下载中：整分片优先**：一旦请求了某个分片的子分片，则该分片剩下的子分片优于其他分片被请求，以尽快获得一个整分片
  - **文件下载中间阶段/平稳期：最少者优先**：选择拥有者最少的分片，最新的分片
  - **最后：尽快取消**。为防止最后阶段的潜在延迟，多发请求；一旦得到最后子分片，就向其它用户发出Cancel消息。

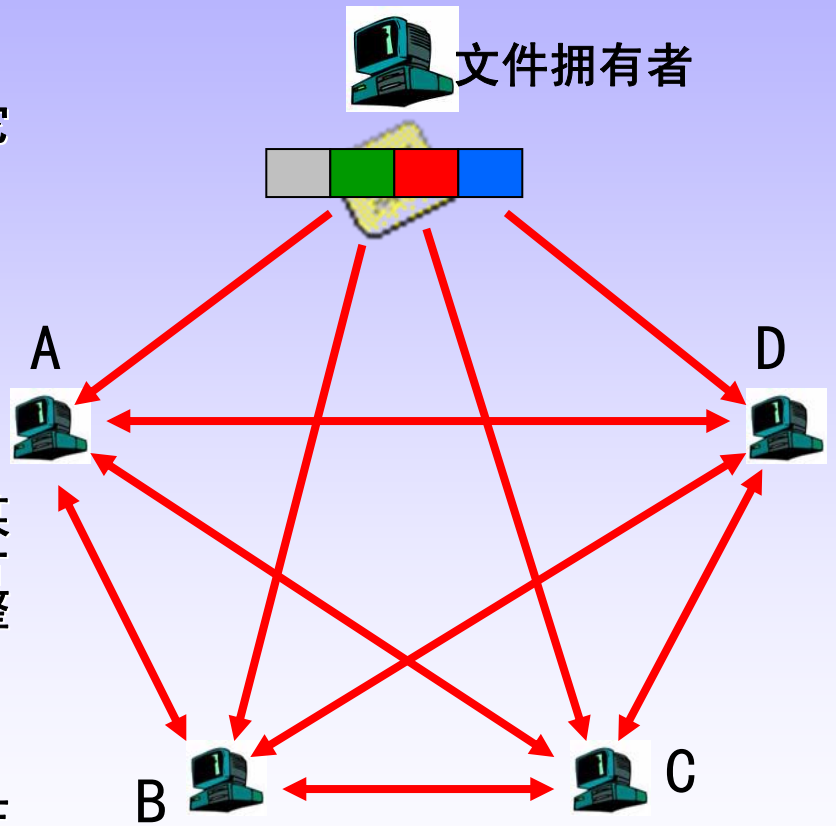

BitTorrent原理

- 协议
  - 种子文件上传下载、Peers和Tracker间通信都是使用HTTP协议
  - 各Peers间通信使用BitTorrent Peer协议
- 问题
  - Tracker的单点失效
  - 未对Peers身份认证
- 开发
  - BitTorrent协议公开，任何人可开发服务器端或客户端
  - 国内流行BitComet，用Python语言开发

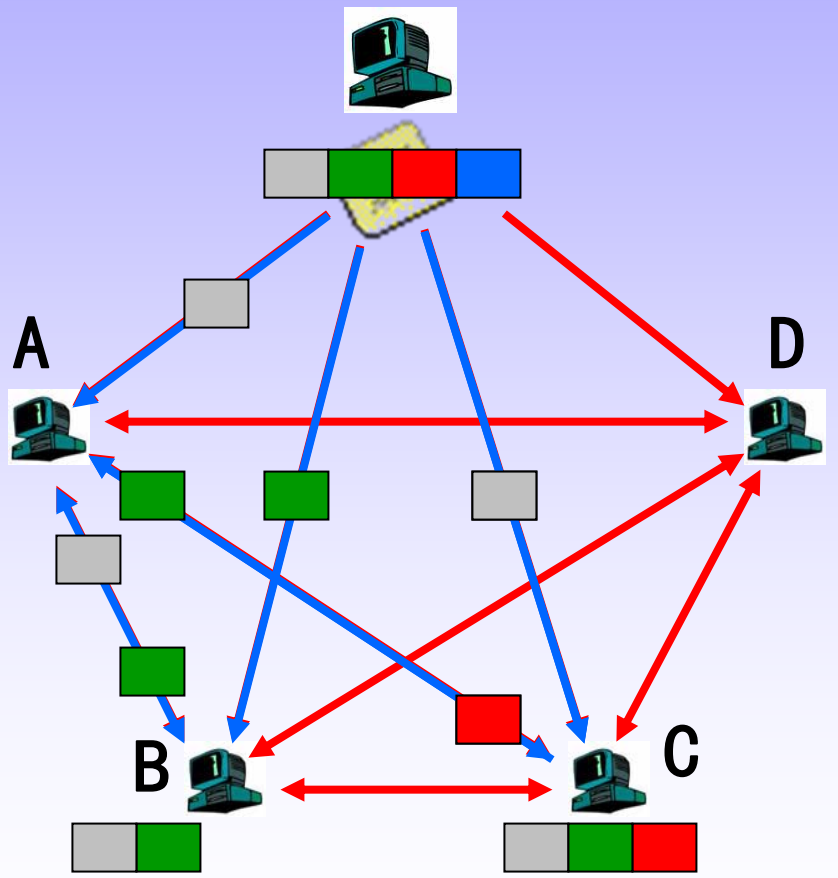

BitTorrent的阻塞算法

- Tracker并不集中分配资源，而由用户控制
  - 尽可能提高自己的下载效率
  - 根据下载方决定对其上传回报（tit-for-tat）针锋相对
    - 对合作者，提供上传服务
    - 对投机者，阻塞对方，暂时拒绝上传服务
- 阻塞算法（Choking algorithm）
  - 经济学背景-Pareto efficient:当系统中资源配置已达到这样一种境地：任何重新改变资源配置的方式，都不可能使一部分人在没有其它人受损的情况下受益。
  - 每个用户一直保持4个邻居的疏通。每个20秒（10+10）轮询，每隔10s决定阻塞谁,并保持该状态10s，10s足够TCP调整传输率到最大
  - 最优疏通（Optimistic unchoking）:不管其下载速率如何，每隔30秒重新计算哪个连接应该是最优疏通。30s足使上传最大

优缺点总结

- 拓扑结构：服务器仍然是网络的核心
- 查询与路由简单高效：
  - Napster和BT的用户访问服务器；服务器返回文件索引或种子文件；用户再直接同另一Peer连接
  - 故路由跳数为O(1)，即常数跳
- 容错、自适应和匿名性
  - 服务器单点失效率高
  - 自组织和自适应主要依靠服务器
  - 服务器的存在使匿名性实际不可能
- 用户接入无安全认证机制

Network Resilience

Partial Topology Random 30% die Targeted 4% die

from Saroiu *et al*., *MMCN* 2002

4.3 无结构P2P网络（第二代）

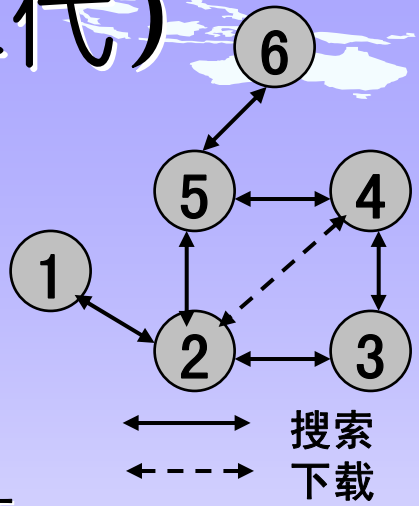

- 过程：**洪泛请求模式**
  - 每个Peer的请求直接广播到连接的Peers
  - 各Peers又广播到各自连接的Peers
  - 直到收到应答或 达到最大洪泛步数(典型5-9)
- 特点
  - 可智能发现节点，完全分布式，无广告性共享资源
  - 大量请求占用网络带宽,可扩展性并不一定最好,
- 协议
  - Gnutella/KaZaA/eDonkey/Freenet使用该模式
  - 消息协议：用于节点间相互发现和搜索资源
  - 下载协议：用于两节点间传输文件（**使用标准的HTTP协议:GET**）
- 改进
  - Kazaa 设立Super-Peer客户软件,以集中大量请求
  - Cache最近请求

- 何为无结构或结构化P2P
  - 根本区别在于**每个peer所维护的邻居是否能够按照某种全局方式组织**起来以利于快速查找。
- 无结构网络优点
  - 将重叠网络看着一个**完全随机图**，结点之间的链路不遵循某些预先定义的拓扑来构建。
  - **容错性好**，支持**复杂查询**
  - 结点**频繁加入和退出**，但对系统的影响小。
- 无结构网络的发展阶段
  - **首先**，文件交换服务以Napster和BT独领风骚，其技术是建立一个大型的集中化：但七大唱片公司把Napster公司推上法庭，三年后法院最终判定Napster侵权。
  - **其次**，**分散式服务以Kazaa**和国内迅速崛起的**POCO**为代表。随机选出品质较优的用户来作为**节点服务器**，从其上获得Peerlist，下载方法也越来越进步。但美国法院最近宣判，这种软件的散播者并未直接控制网络上所出现的行为。
  - **再者**，以早期eDonkey、emule、Morpheus为代表，比以前更为分散化。它采用**DHT**的方法，基本上是对网络上某一特定时刻的文件进行快照（snapshot），然后将这些信息分散到整个网络里。

4.3.1 Gnutella

- 背景
  - 2000.3诞生于Nullsoft公司，由MP3播放软件WinAmp的设计者Justin Frankel和Tom Peper发明
  - 3.14日Napster版权案出现后，其母公司AOL（America On Line）在该软件于Gnutella网站上公布仅1.5小时后就关闭了该网站
  - 但就在这1.5小时间几千用户MP3迷下载了Gnutella，并将其公开、改造和克隆，保留下来。
- 现状：Gnutella更多指无结构P2P网络协议
  - gnutella.wego.con:改造或克隆软件
  - www. gnutellaworld.net:交换各种相关信息
  - Rfc- gnutella.sourceforge.net:协议文档0.4，0.6建议使用UltraPeer
  - www. Gnutella.com：商业网站，各种应用软件集合和联盟

认识Gnutella

- Gnutella是开源码
- 衍生出Windows/Linux平台下诸多客户端
- 最新Windows平台下的Phex
- 下载地址：www.gnutella.com

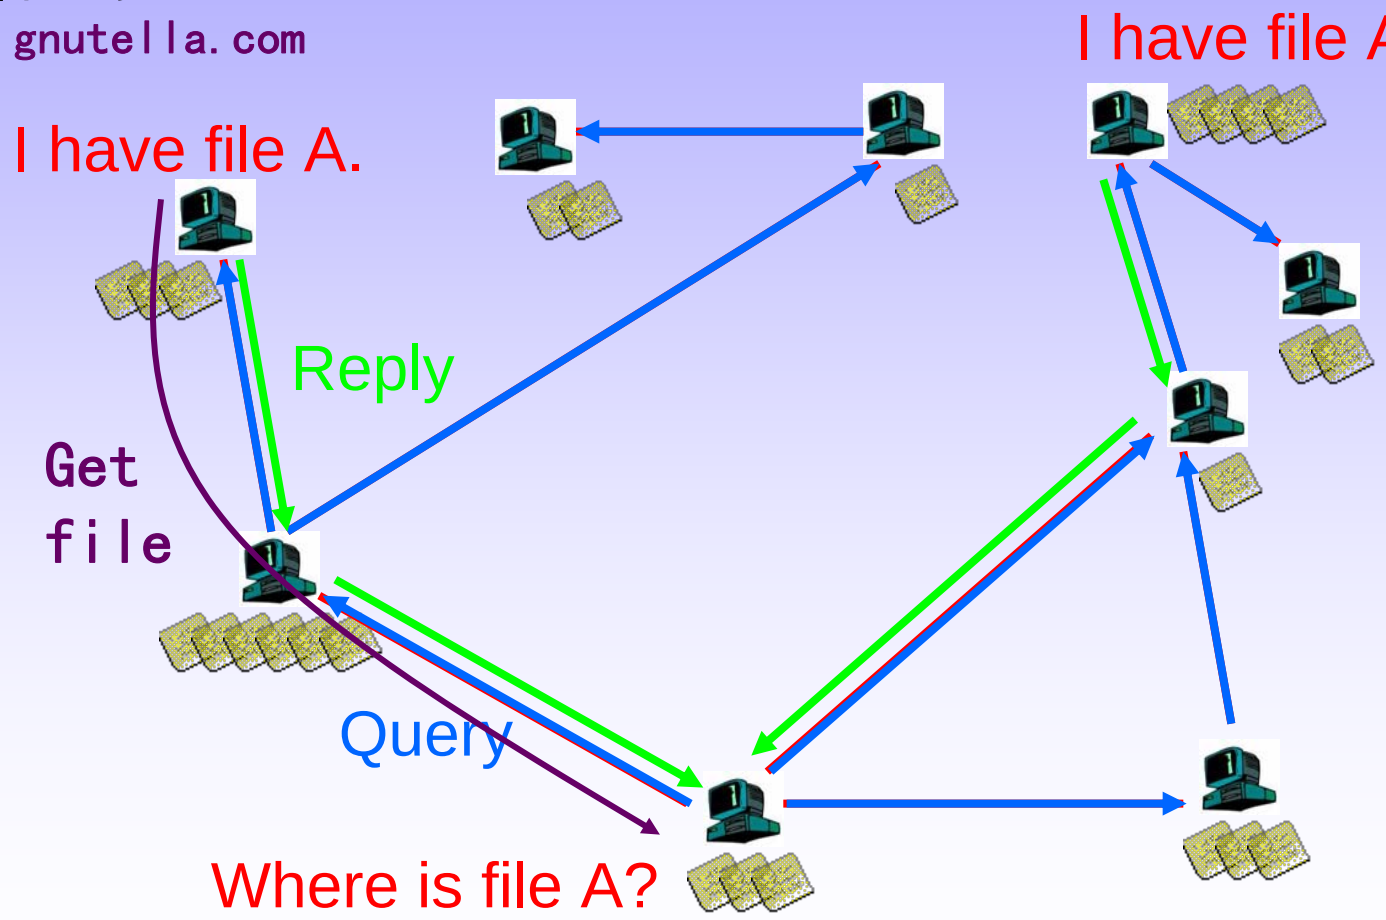

Gnutella: Example

- Assume: m1's neighbors are m2 and m3; m3's neighbors are m4 and m5;...

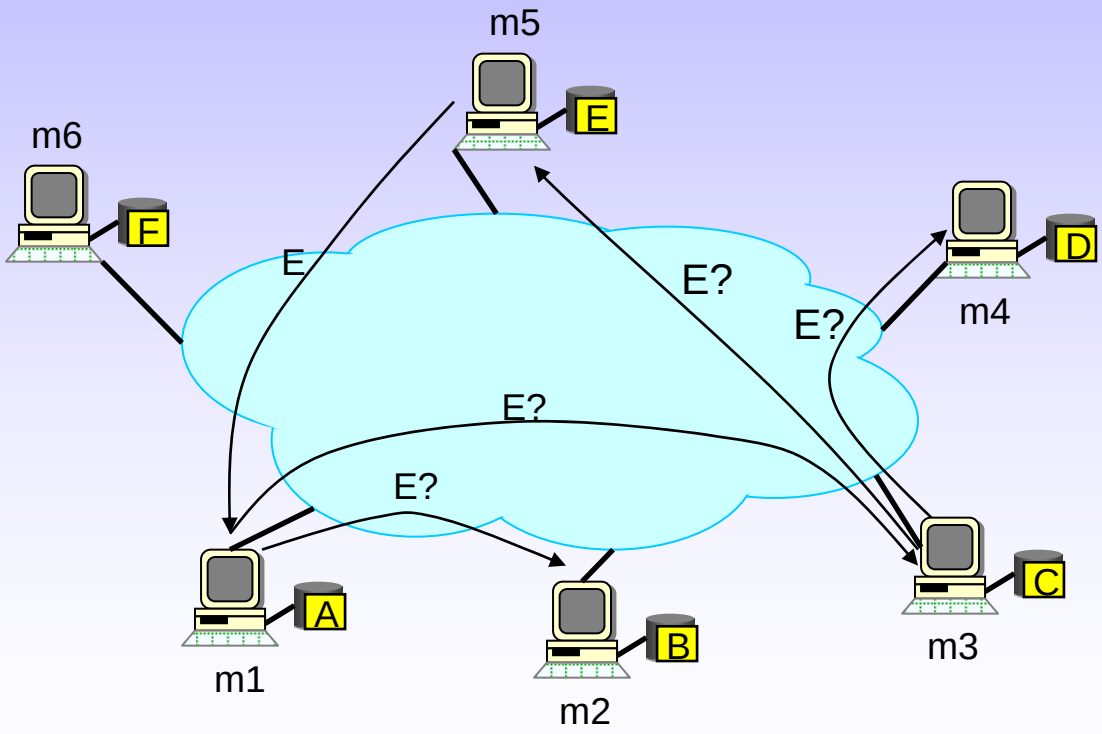

Gnutella原理

- **纯分布式对等**
  - 每个Peer即使服务器也是客户机
  - 每个Peer监视网络局部的状态信息，相互协作
- 工作过程
  - 原始加入：必须首先连接到一个“众所周知”几乎总是在线的【或称中介、**自举**、入口】节点（功能同一般Peer），进入Gnutella网
  - 查询和应答消息采用**广播或回播**（Back-propagate）机制
    - 每条消息被一个全局唯一**16字节随机数编码为GUID（128 bit）**
    - 每个节点**缓存最近路由的消息**，以支持回播或阻止重广播
    - 每条消息都有一个**TTL数**，每跳一次减少一次

Gnutella典型消息

- 组成员消息
  - Ping：新节点加入网络时用=I am here !;探测其它节点=Are you there?
  - Pong:收到ping后决定是否回播pong消息，然后将ping广播给邻居节点（含IP地址、端口号、共享文件数量和大小）=Yes, I am here
- 查询消息
  - Query:指定查询文件和响应速度等信息，每个查询有唯一ID= I am looking for...
  - Query Response:回应包含IP地址、端口号、位置和带宽等信息，以及命中节点的NodeID,本消息沿来路回播=Your wanted file is here...
- 文件传输消息
  - Get:获取文件 = I'll get...from you
  - Push:请求Firewall后的文件拥有节点，主动建立连接把文件上传给自己 = I can't get...from you ,so you push it to me

Gnutella的问题与改进

- 洪泛广播加重网络带宽**负担**，受TTL限制，消息只能达到**一定范围**，这又导致有些文件**不能查询到**？
- 基本呈**幂率分布**：有**连接数L的节点数占网络总节点数的%比**，正比于L^{-a}，Gnutella的**a=2.3＜3**，节点随机失效的容错性很高→可有效防止某些节点失效而使Gnutella分裂
- 改进：**分层P2P**=增加**超级节点负责查询消息的路由**，构成P2P**骨干网**，叶节点只是通过**超级节点代理**接入

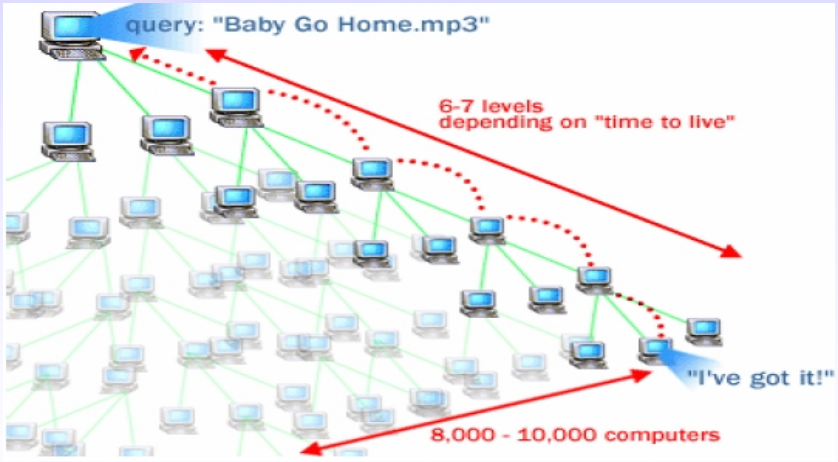

最初的Gnutella采用的Flooding搜索算法示意图

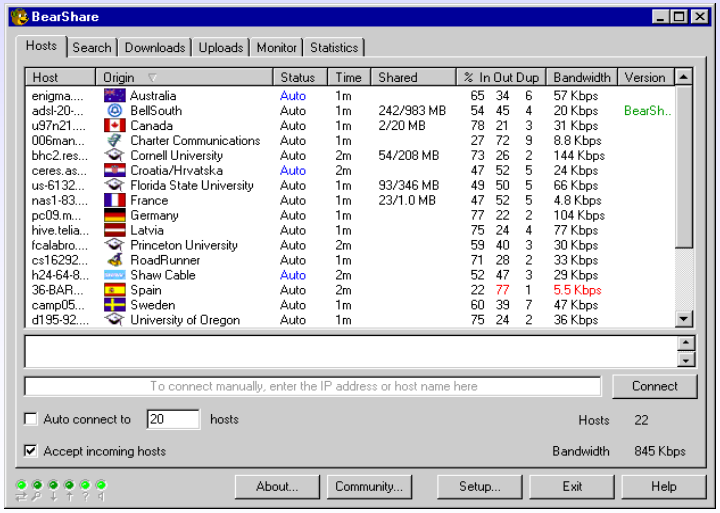

采用第二代Gnutella协议最经典的软件-Bearshare

4.3.2 基于超节点的KaZaA

- 2000.7，斯堪的纳维亚的Niklas和丹麦的Friis开发
  - Niklas是著名P2P企业家，在KaZaA之后，创办了
  - Joltid公司：推广P2P解决方案和P2P流量优化技术
  - Altnet公司：第一个安全应用P2P网络，发行数字版权管理许可证
  - Skype公司：全球第一家实时语音通信公司
- 基于FastTrack协议
  - 比Gnutella早引入SuperNode
  - KaZaA是专有协议，对消息加密，存在超级和普通两类节点
  - 超级：高带宽、高处理能力、大存储容量、不受NAT限制
  - 普通：低带宽、低处理能力、小存储容量、受NAT限制
- 加入、上载与查询
  - 普通节点选择一超级节点作为父节点加入，并维持半永久TCP连接
  - 将自己贡献的文件元数据、描述符上传给它，并生成Hash值
  - 父超节点根据文件描述符关键字查询，返回文件所在IP地址+元数据

KaZaA共享文件过程

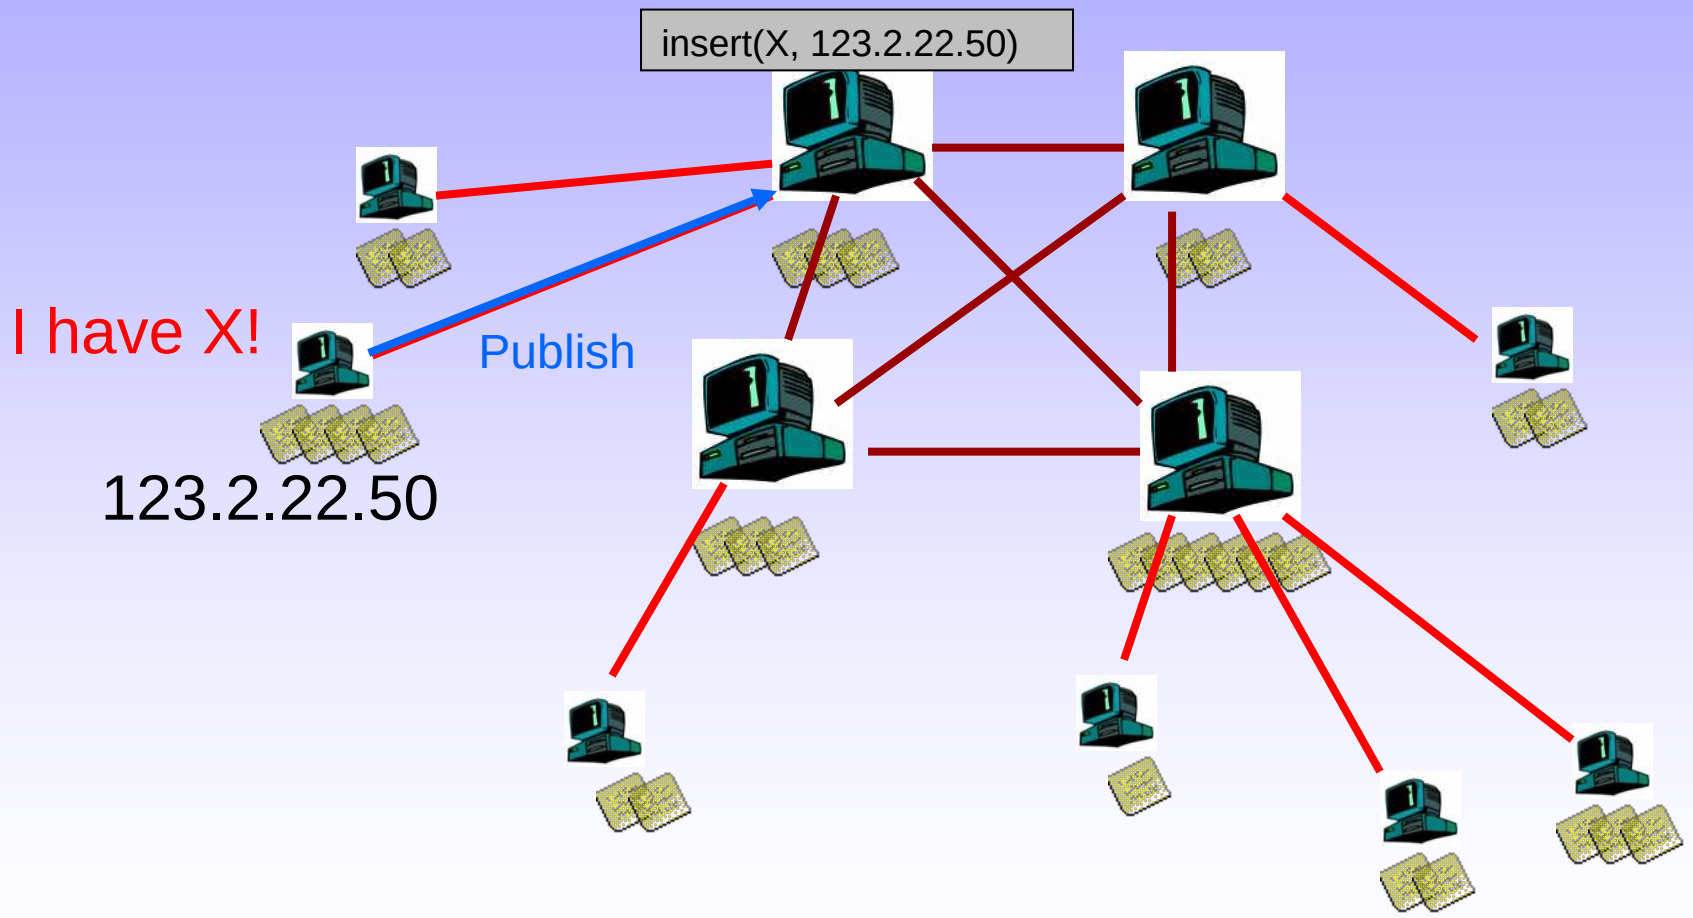

KaZaA原理

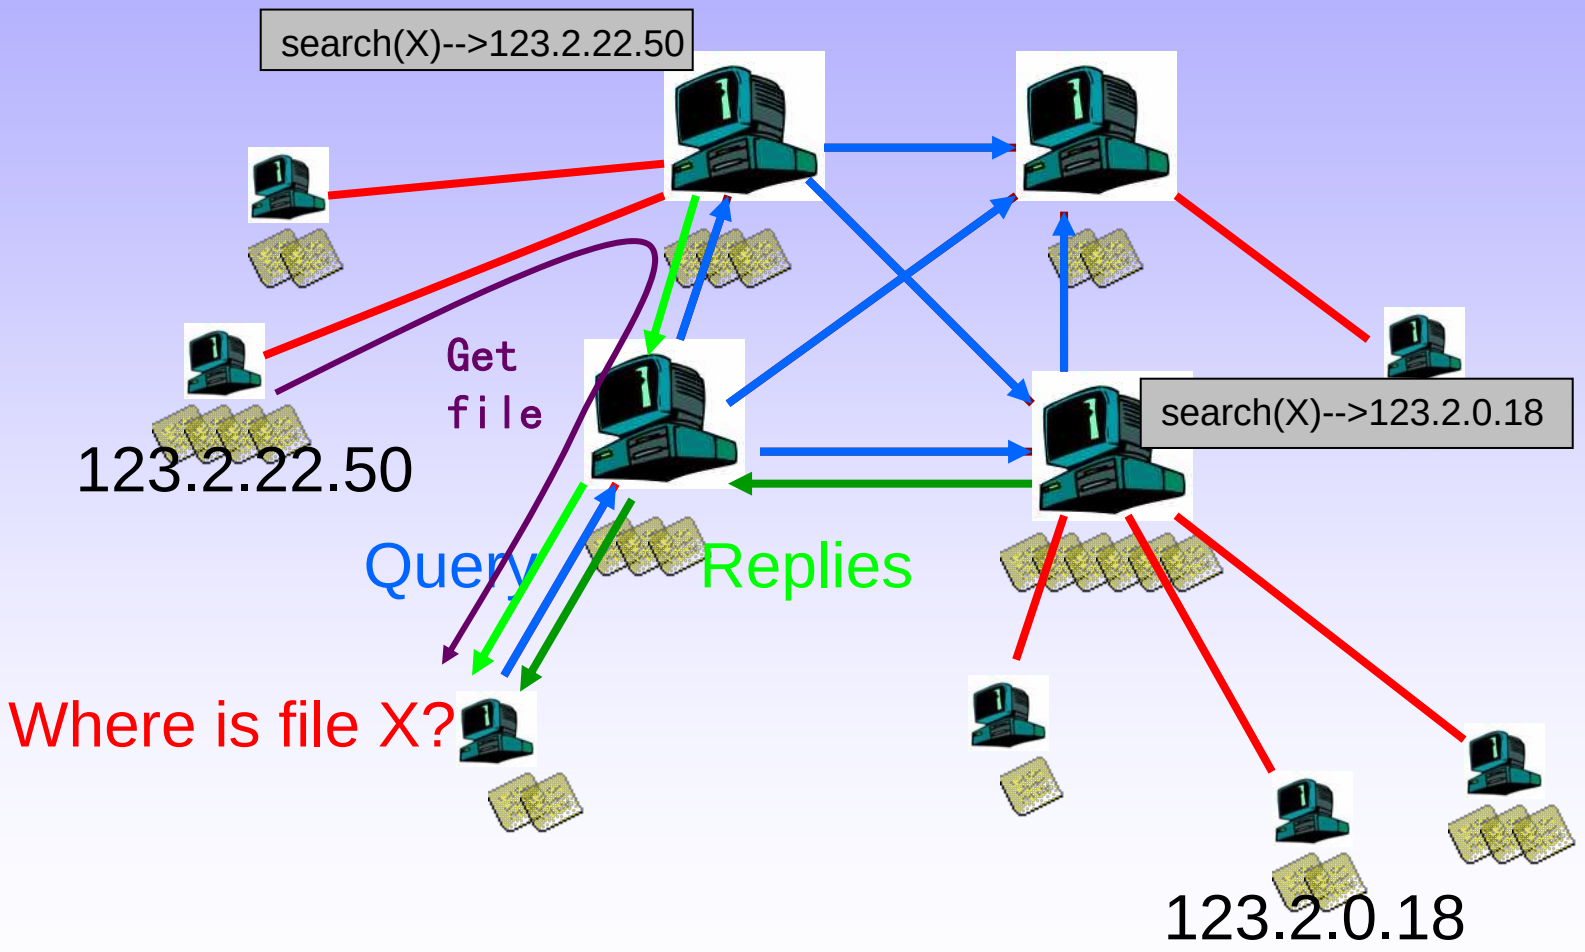
search(X)-->123.2.22.50
Get file
123.2.22.50
search(X)-->123.2.0.18
Query
Replies
Where is file X?
123.2.0.18

KaZaA连接的建立和消息格式

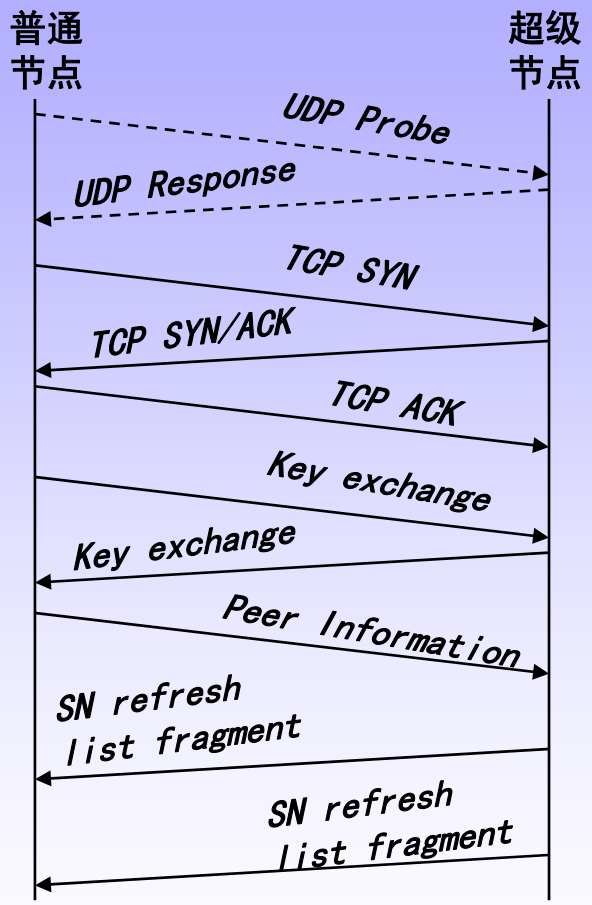

普通到超级连接的建立

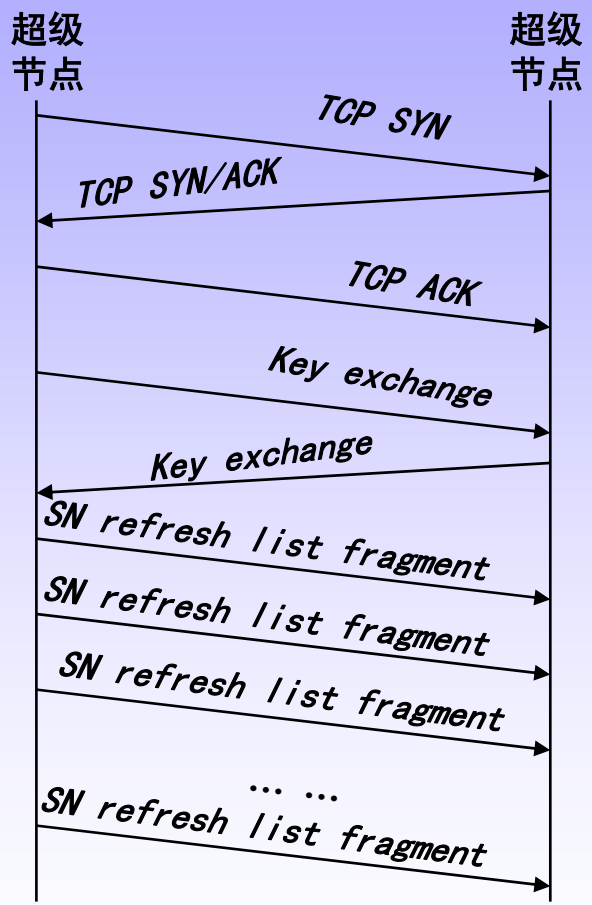

超级节点间连接的建立

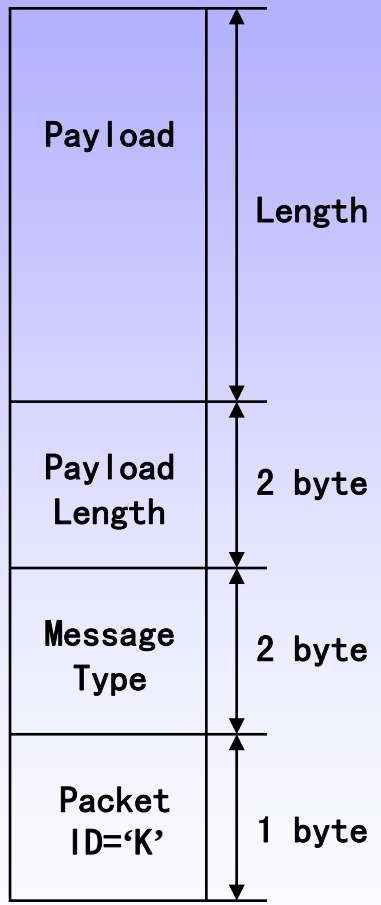

消息格式

4.3.3 eDonKey/eMule/Overnet

- 背景
  - eDonKey，2000年，Jed McCaleb创立
    - 与BT类似，文件分块下载；内容Hash作完整性验证，服务器为核心
    - BT是基于文件、由 Tracker服务器来查询、搜索和跟踪用户；但eDonKey 是基于用户的类似KaZaA的超级节点。
  - eMule，2002.5.13， Merkey因不满eDonKey客户端
    - 在eDonKey加入新功能、优化图形界面
  - Overnet是一个独立的分布式搜索应用
    - 被eDonKey整合到自己的体系中
- 特点
  - 分块下载的双层无结构P2P网络

eDonKey 结构与过程

- 结构
  - 服务器层S或超节点+客户端层C
  - S间交换文件索引和服务器列表
  - 每个C连接到一个S进行文件查询和S列表更新
- 加入与查询
  - 连接最适合S
    - 与过去“入口S”列表中的S建立连接，从中选择离自己延时最小的那个
    - 通过入口S获得普通S列表，从此表中选择最适合S连接，并断开原入口S
  - 上载共享文件：客户A上载索引到S
  - 查询：客户k向C/D发出查询
  - 回答：返回索引=文件名+大小+位置
- 连接方式
  - C←→S间TCP/4661；深层查询UDP/4665
  - C←→C间TCP/4662
  - 动态自适应：下载者每40s向上传者重发下载请求，否则关闭连接
  - S←→S间周期性交换服务器列表

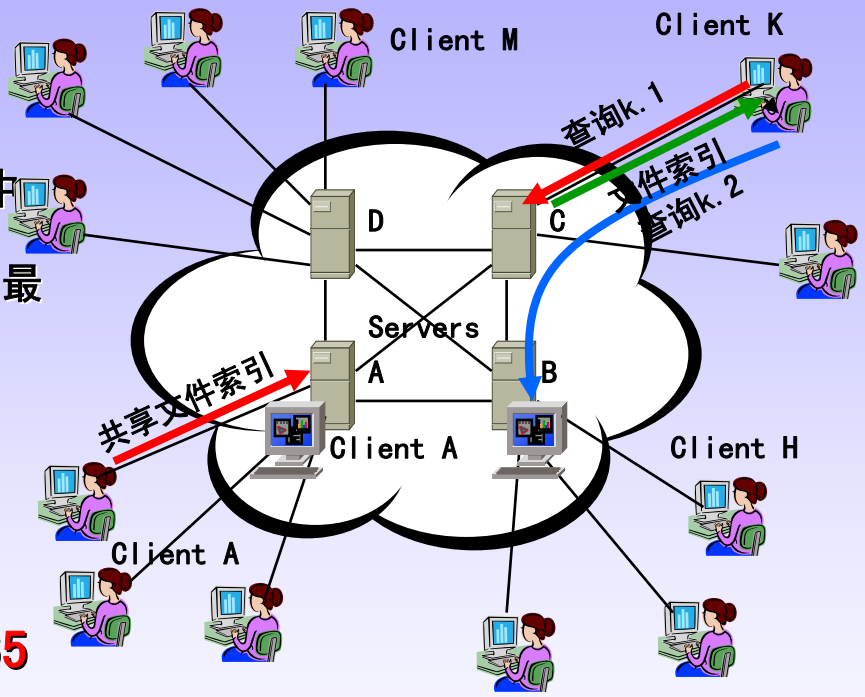

eDonKey分块及性能测量

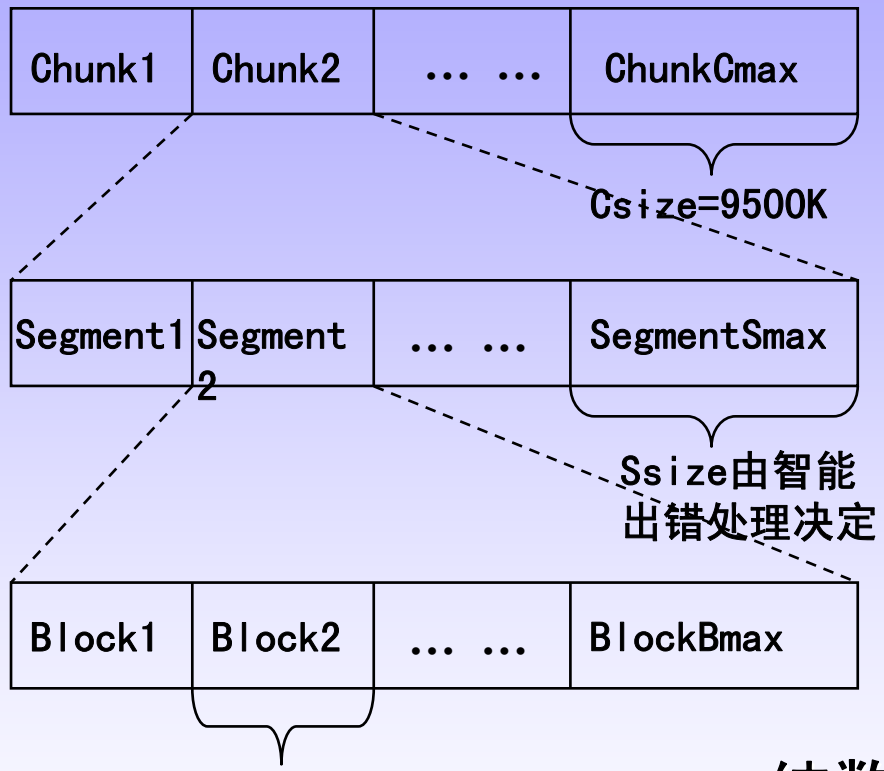

eDonkey文件分块细节

C←→C间TCP/4662上的网络参数测量

‘4662’端口所有连接	343.1743万
本地主机数	25
外部主机数	24.2067万
所有流的传输总量	295 G Byte
下载连接的传输总量	208 G Byte（70.5%）
下载连接数	7.7111万（2.24%）
从外入境下载连接数	2.1344万（27.7%）
从内处境下载连接数	5.5767万（72.3%）

- 纯数据下载比70.5%并不高
- 仅2.24% 的数据连接却承担了70.5%的通信量
- 总体不如BT

4.3.4 无结构网络总结

- 覆盖网络的拓扑特性
  - 用户自发形成的、随机松散、任意形状的普通拓扑
  - 但也符合内在某些规律
    - 小世界模型：5-6跳找到（人、信息）
    - 幂率模型：互联网中有连接数L的节点数占网络总节点数的份额正比于L^{-a}，a是网络本身的常数因子
- 路由和定位方法
  - 洪泛法
    - 预先不知道数据在何处？路由存在很大随机性
    - TTL 控制洪泛半径，大于半径的可能存查不到
  - 扩展环：试探性洪泛，不断增加TTL
  - 随机走：随机选择一个邻居行走，直到TTL耗尽
  - 超节点路由
- 容错性与自适应
  - 幂率特性对随机节点失效有高容错性
  - 自适应：检测邻居在线否
  - 超级节点列表定期更新
- 可扩展性
  - 改造洪泛提高可扩展性
- 安全性与匿名性
  - 无结构不易追踪
- 增强机制—复制
  - 查询分布：均匀、Zipf
  - 复制份数：均匀、依查询概率比例、方根复制
- 优势和缺陷
  - 高容错性和良好自适应性，较高安全性和匿名性
  - 路由效率低/可扩展差/准确定位差

无结构网络的缺点

- 无确定拓扑结构的支持
  - 无法保证资源发现的效率。即使需要查找的目的结点存在发现也有可能失败。
  - 由于采用TTL（Time-to-Live）、洪泛（Flooding）、随机漫步或有选择转发算法，因此直径不可控，可扩展性较差。
- 面临两个重要问题
  - 发现的准确性
  - 可扩展性的
- 目前研究主要集中：提高发现的准确率和性能
  - 改进发现算法
  - 复制策略

4.4 结构化P2P网络（第三代）

- P2P网络拓扑演进背景
  - 1999，混合式
  - 2000，无结构
  - 2001，结构化
- 2001年后学术届开始关注
  - IEEE成立P2P专业协会
  - ACM成立SIGCOMM
  - 国际会议/刊物发表论文
- 提出第三代模型
  - Chord/CAN/Tapestry
  - Pastry/CFS/PAST
- 成立专门研究机构
  - MIT的Chord和CFS
  - UC Berkeley的Tapestry和OceanStore
  - 微软和Rice大学的Pastry和PAST
  - Stanford的Peers研究组
- 商业领域大发展
  - 基于异或度的Kademlia网络被BT/eDonkey/eMule所使用
  - Azureus/eXeem等

4.4.1 分布式哈希表结构

- Distributed Hash Table
  - 把涉及全系统的数据表，分布分段存储在各节点中，并通过Hash方法进行插入和查询
  - 分布式数据结构可以是环/树/超立方体/跳表/蝶形网,CFS, OceanStore, PAST, Chord CAN ...采用
- DHT的特点
  - 能自适应结点的动态加入/退出
  - 有着良好的可扩展性、鲁棒性
  - 结点ID分配的均匀性和自组织能力。
  - 确定性拓扑结构可精确发现

Distributed Hash Tables (DHT)

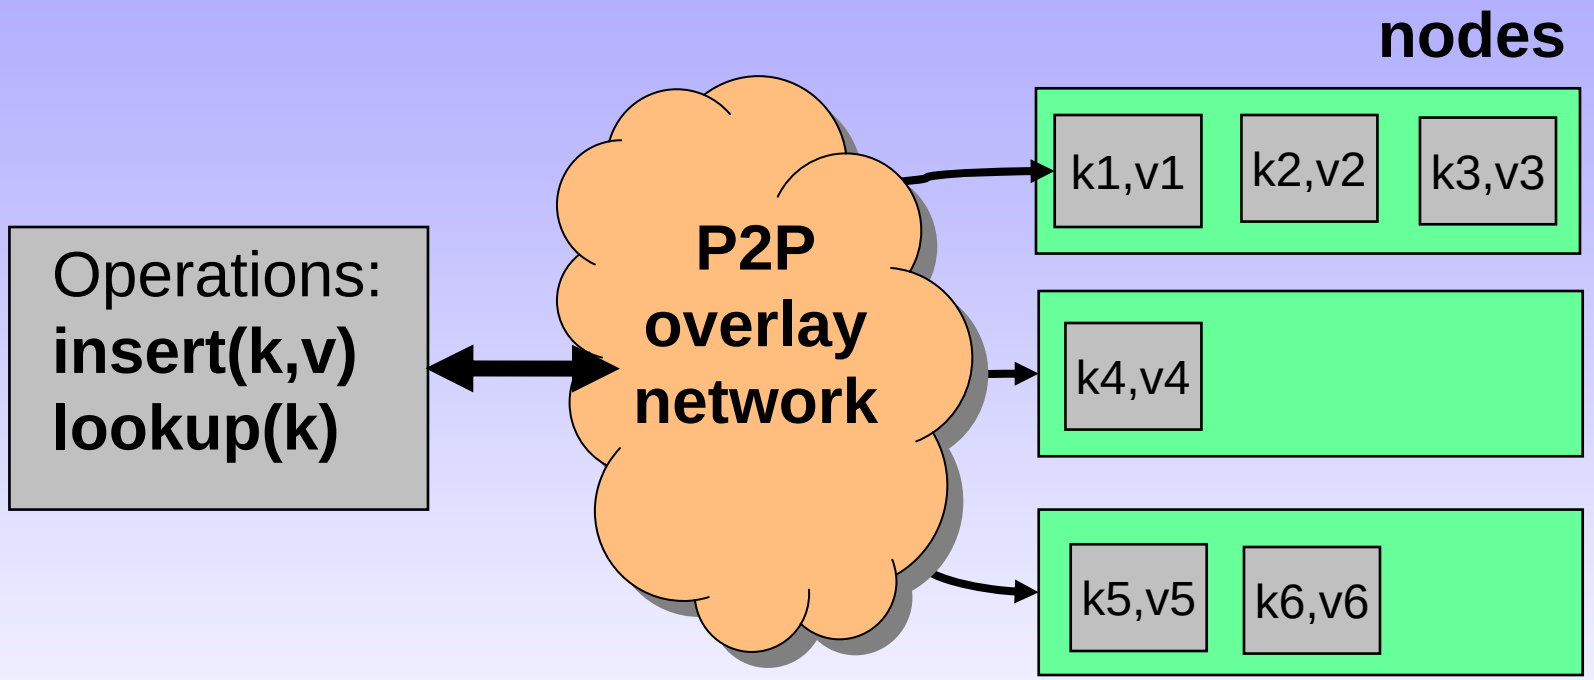

- p2p overlay maps keys to nodes
- completely decentralized and self-organizing
- robust, scalable

Distributed Hash Table 历史

- DHT:2000-2001年，理论研究者加入
- 动机
  - 这些不成熟的P2P应用竟然如此流行，“我们可以做得更好”
  - 保证系统中的文件能够被找到
  - 保证搜索时间在可证实的范围
  - 保证数百万节点的可伸缩性
- 成为研究热点

- 设计目标
  - 非中心化
  - 原子自组织
- DHT是什么？
  - 一个由广域范围大量结点共同维护的巨大散列表
  - 它被分割成不连续的块，每个结点被分配给一个属于自己的散列块，并成为这个散列块的管理者。
  - DHT的结点是动态的，数量巨大
  - 通过加密散列函数，一个对象的名字或关键词被映射为128位或160位的散列值。
  - DHT结点被映射到一个空间
- DHT的起源
  - 起源于SDDS（Scalable Distribute Data Structures）研究，Gribble等实现了一个高度可扩展，容错的SDDS集群。

- 结构化重叠路由
  - 加入：开始时，联系一个“bootstrap”节点，加入分布式数据结构，获得一个节点id
  - 发布：向数据结构中最近的节点发布文件id的路由信息
  - 搜索：向路由表中最近的节点查询文件id，数据结构保证查询会找到发布节点
  - 获取：两个选项
    - 查询到的节点保存有文件，则从查询结束的节点获取
    - 查询到节点返回结果：节点x有文件，则从节点x获取

DHT技术

- 节点与资源的编址
  - NodeID：结点按照一定的方式分配一个唯一结点标识符
  - ObjectID：资源对象通过Hash运算产生一个唯一的资源标识符
- 定位
  - 资源以文件形式存在
  - 把文件名或关键字等文件属性信息抽象表示为Key
  - 把文件内容或存储该文件节点的IP 地址抽象表示为Value
  - 每个文件有一一对应的二元组<Key,Value>
- 资源上载
  - 资源Object ID将存储在与结点ID之相等或者相近的结点上
- 资源下载
  - 通过<Key,Value>定位到存储该资源的结点，并直接下载

4.4.2 Chord/CFS

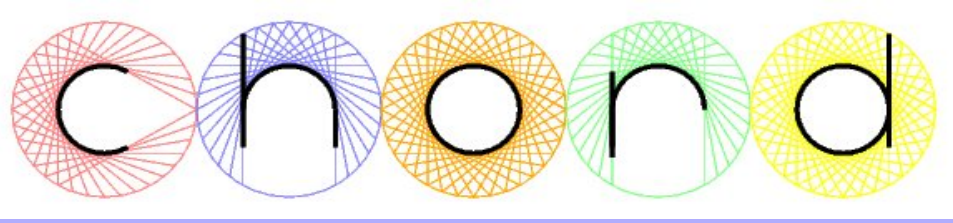

- 环形P2P网络
  - Chord：弦/带环弦。最简单、优美而精确的P2P网络
  - 在N个节点的网络，每个节点保存O(logN)个其它节点的信息
  - 在O(logN)跳内可找到存储数据对象的节点
  - 节点离开或加入网络时，保持自适应所需消息数$O(\log^2 N)$
  - 可提供数据对象的存储、查询、复制和缓冲
  - 在其上构架有协同文件系统CFS（cooperative file system）

Chord基础工作原理

- ID的分配：通过安全hash函数(如SHA-1) (Secure Hash Standard)
  - nodeID=H(node属性)=H(IP地址/端口号/公钥/随机数/或其组合)
  - objectID=H(object属性)=H(数据名称/内容/大小/发布者/或其组合)
  - SHA-1的长度值≥160 Bits = m ，从而保证其唯一性和几乎不重复性，故nodeID/objectID均可在[0...2^m]中选取
- 索引的分配
  - nodeID从小到大、顺时针排列于1个环上
  - 对象k的后继Successor(k)节点:数据对象k(即objectID)也按环上顺时针方向，分配到节点k或第一个比k大（mod 2^m ）的节点上
  - 形式化表示 Successor(objectk) = nodek 或 nodex mod 2^m ，x是现存网上顺时针第一个大于k的节点
- 查询索引
  - 按上述后继关系，Chord显然可以正确工作
  - 但效率低下，找到紧邻后的节点显然要顺藤摸瓜O(N)个节点

把内容key分配到其后继节点

H(天堂1.MP3)= ObjectID =1=key1

Successor(key1)=1=N1

H(天堂2.MP3)= ObjectID =2=key2

Successor(key2)=3=N3

H(天堂6.MP3)= ObjectID =6=key6

Successor(key6)=0=N0

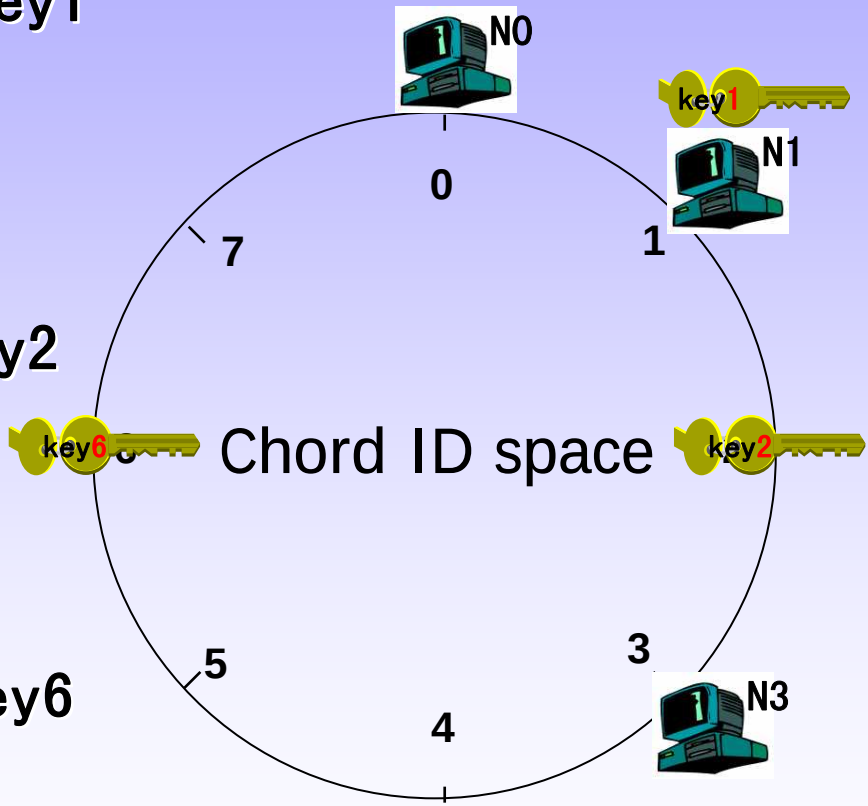

节点路由表的分配

- 用路由表：使每步更快接近目的节点
- 指向表：finger table
  - 每节点存储m项大小的路由表，以减少路由跳数
  - 每个节点表存m个路由项；节点n的路由表中，第i项指向节点 s = successor(n+2^i),0≤i≤m-1
  - 故s是在顺时针方向到n的距离至少为2^{i-1}的第一个节点：记作n.finger[i].node；也就是n.successor
  - 一个路由表项还包括相关节点的nodeID和IP地址、端口号。
- 特点
  - 每节点只保存很少其它节点信息，且对离它越远的节点所知甚少
  - 节点不能从自己的路由表中直接看出对象k的后继节点
- 前驱节点：Predecessor(k)
  - 在k之前，不等于k且离k最近的节点Predecessor(k)
  - 节点n在自己的路由表中寻找在k之前且离k最近的节点j，让j去找离k进一步最近的节点，如此递归下去，j将离k越来越近，最终找到k的前驱节点
  - n的前驱节点为n.predecessor

Chord的自组织与路由表

- 假设id空间是 [0..2^m-1]
  - m=3, [0.. 7]; 0≤i≤2
- 节点1加入
  - 即id=1之节点加入
- 理解后继节点表
  - if Min|KeyID-(id+2^i)| then goto 对应succNode

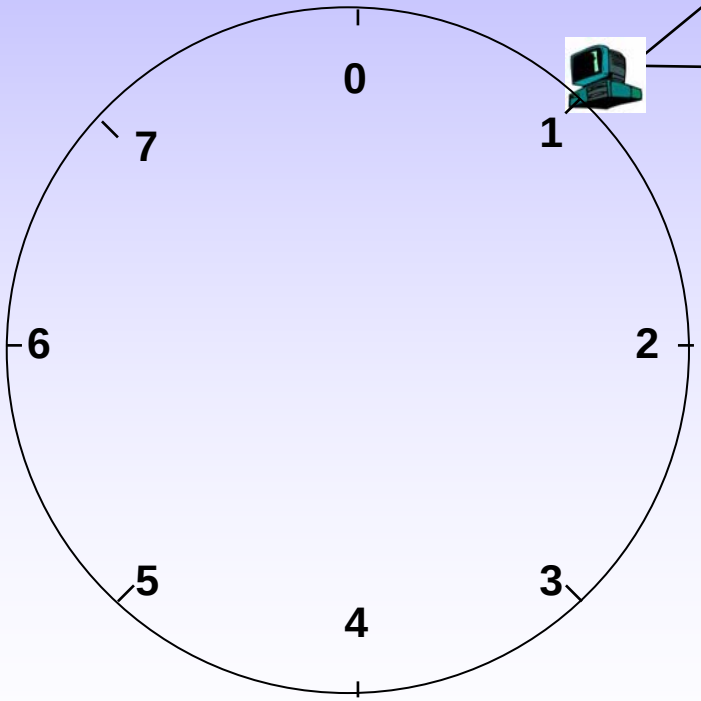

Succ. Table

i	$id+2^i$	succ
0	2	1
1	3	1
2	5	1

Chord自组织与路由表

- 节点2加入

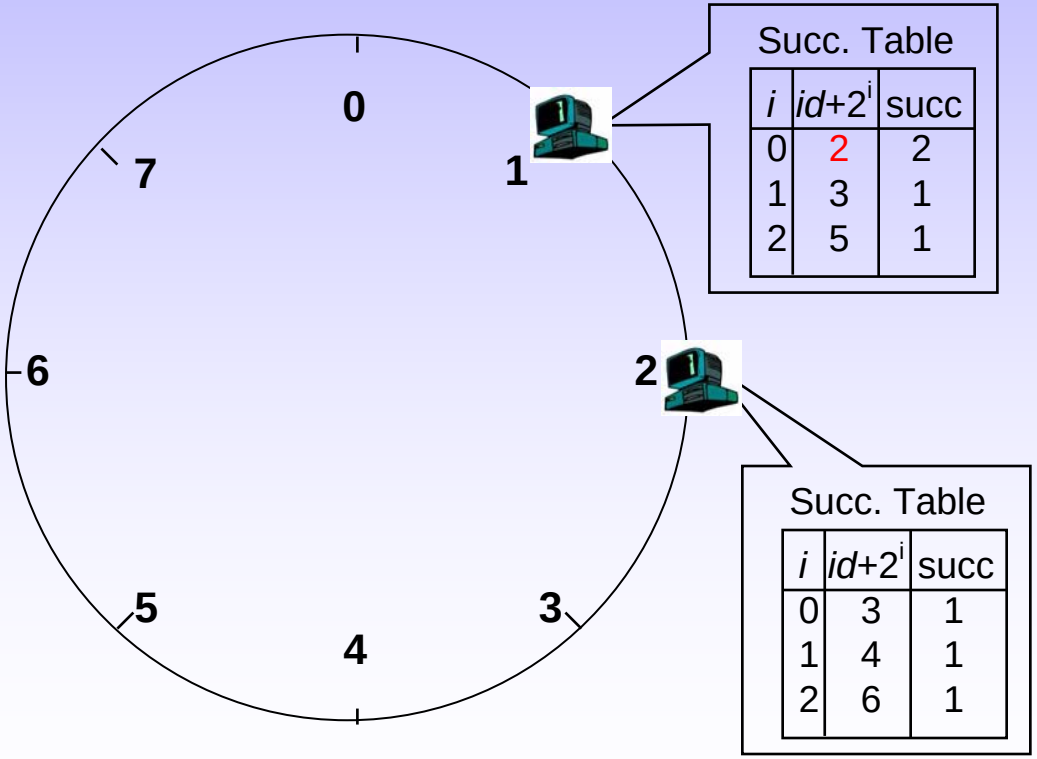

Chord路由表的变化

- 节点0，6加入

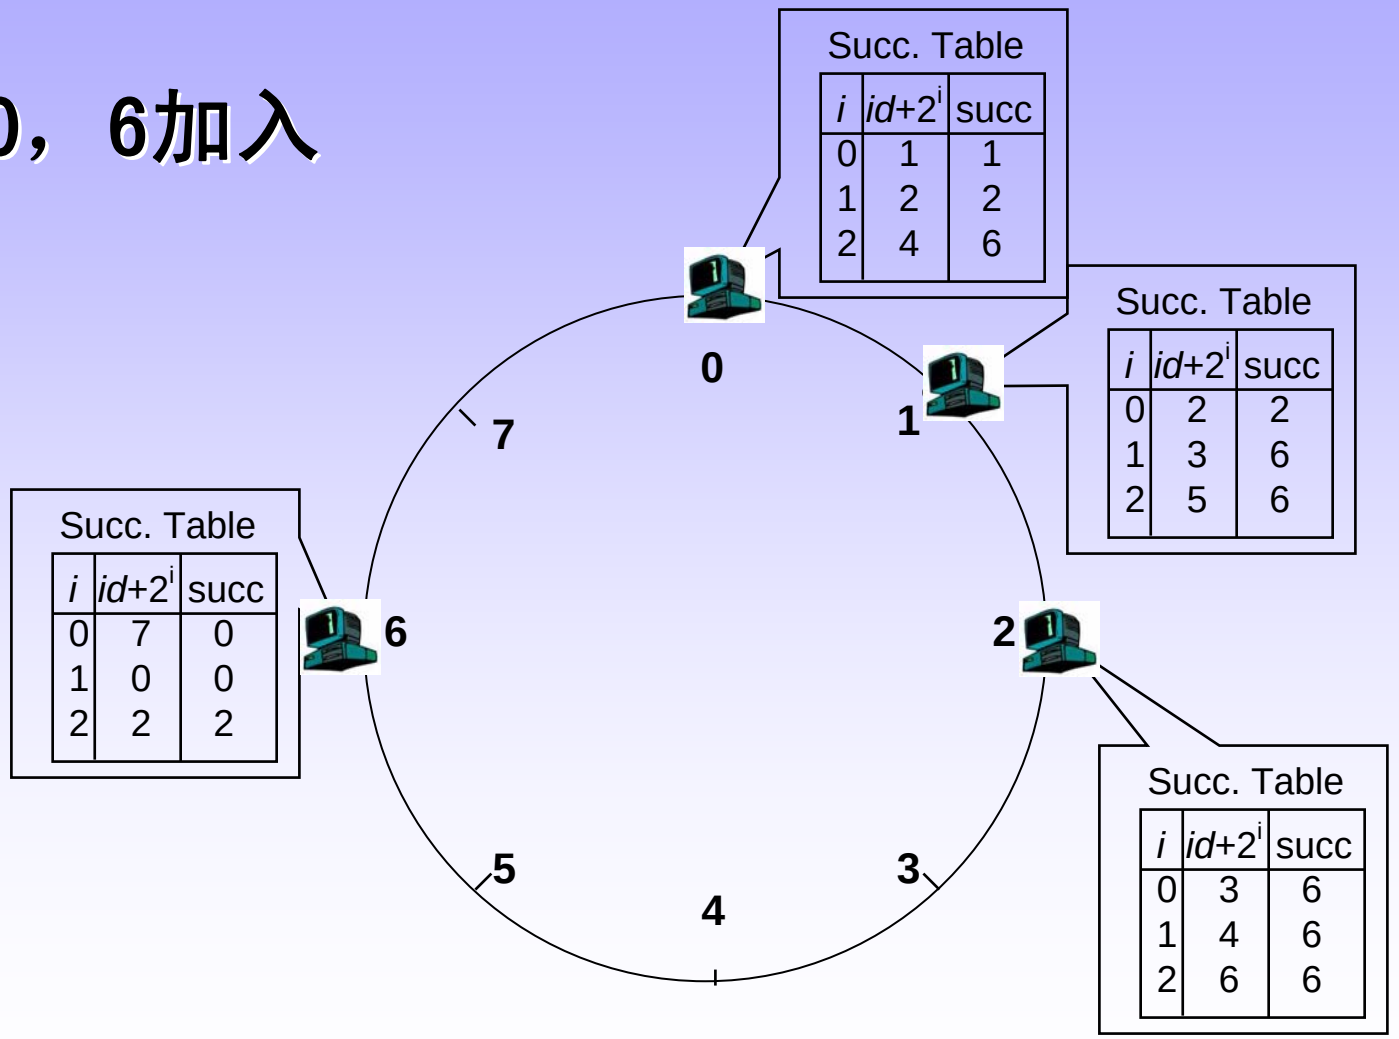

Chord路由表的变化

- 节点：1，2，0，6
- 文件上载:文件索引 7，1
  - 文件keyid 同在环空间[0..2^m-1]

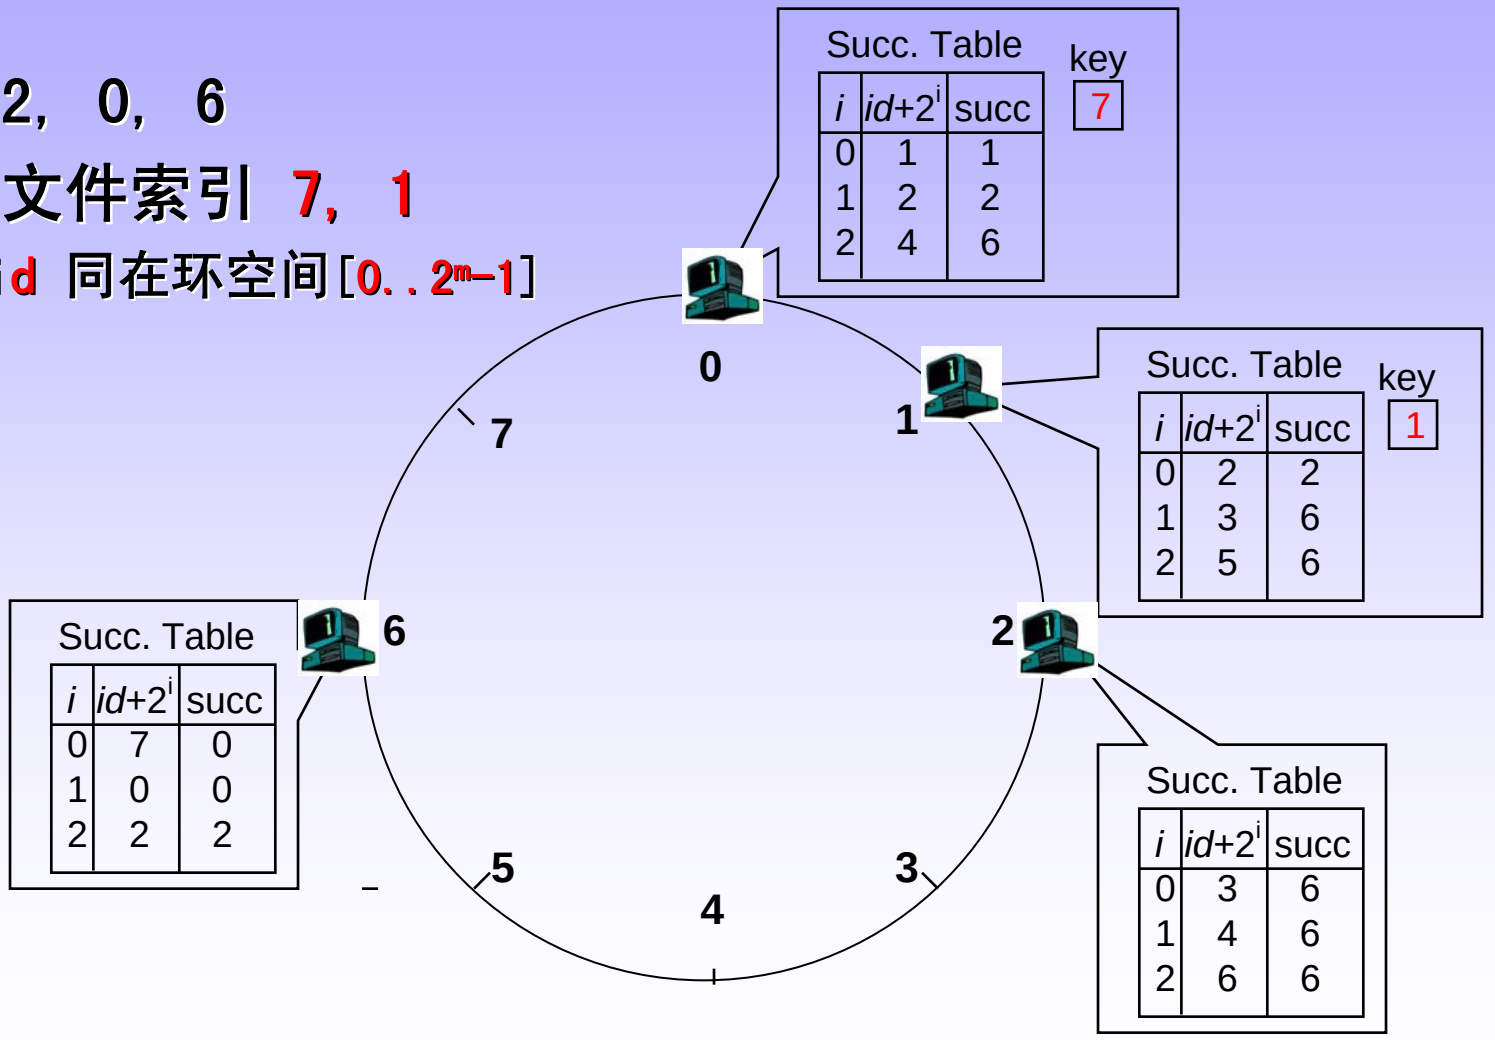

Chord查询

- 当节点1收到查询key=7请求后：
- key=7存在本地否?；
- 否，转发查询到路由表中与目标最近的id（不超过请求id）

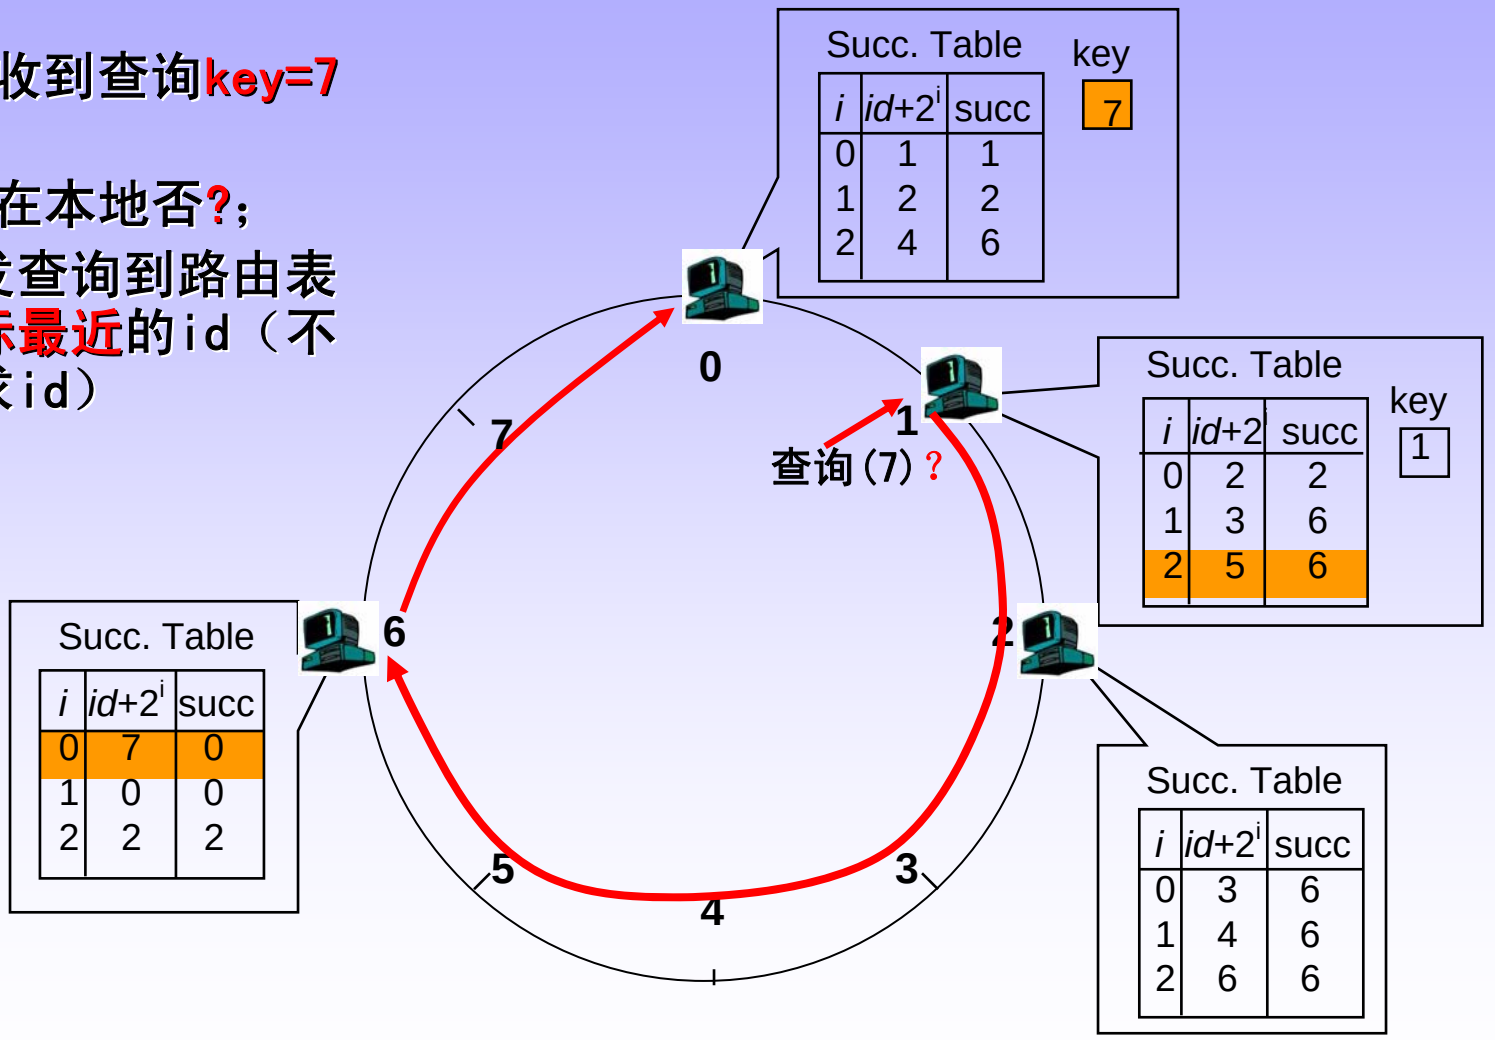

协同文件系统CFS简介

- CFS是以Chord作为基础的P2P只读文件存储系统
  - 依靠Chord作为其分布式HASH表，提供高效、容错和负载均衡的文件存储和获取
  - 系统由文件系统FS、分布式散列表DHash和底层定位散列表Chord三层构成
  - 每个节点既是服务器又是客户机
- 功能说明
  - FS:高层，从DHash层获取数据块，将这些快转换成文件，给更高层文件系统接口
  - DHash：中间层，分布和缓存数据块以负载平衡，复制数据块以容错，通过服务器选择来减少延迟，用Chord定位数据块
  - Chord：底层，维护路由表，定位数据块所在的服务器

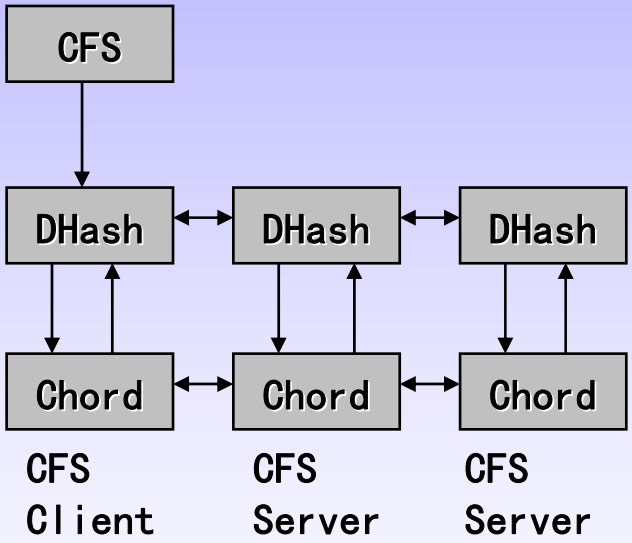

CFS的系统结构

Chord：总结

- 简单、精确，但要求
  - 每个节点的**后继节点始终准确**
  - 每个对象k的后继节点**始终承担k的索引**
- 每个节点维护DHT的**一小部分表**，大小=LogN = m
  - 其中**第i项**保存距自身的**间隔至少为2^{i-1}的第一个节点**的位置信息
- 查询与维护代价
  - 查询代价：m项的平均间隔 delta = $[2^0+ 2^1+... +2^{m-1}]/m$ ；设经J跳命中，应总跳数应≤2m ；故 J*delta≤2^m ；故有J≤m = O(log N) ； 一次查询的路由平均跳数为**O(logN)**
  - 维护代价：节点的进/出，自适应到最新状态需**$O(\log^2 N)$**
- 缺点：
  - 没有实际使用（只有一个文件共享应用）
  - **不支持**非精确查找

Discussion

- Query can be implemented
  - Iteratively
  - Recursively
- Self-organization
  - Join and leave
  - Gracefully and abruptly
  - Distributed or locally
- Performance: routing in the overlay network can be more expensive than in the underlying network
  - Because usually there is no correlation between node ids and their locality; a query can repeatedly jump from Europe to North America, though both the initiator and the node that store the item are in Europe!
  - Solutions: Tapestry takes care of this implicitly; CAN and Chord maintain multiple copies for each entry in their routing tables and choose the closest in terms of network distance

4.4.3 内容可寻址网络CAN

- Content Address Network背景
  - Ratnasamy等2001年ACM会发表，与Chord相提并论
- 基本思想
  - 采用**多维空间拓扑结构**，严格是**多维环面**结构（Torus）
  - 空间**动态分配**给网络各节点，每个节点有一个属于**自己的方块**并负责方块中的所有**“点”**
  - 每个**数据对象**通常被**唯一映射**到多维空间中的一个**“点”**，由负责该点的节点来存储该**数据对象的索引**
  - 每**点维护一个路由表**，**记录**它在多维空间上的**邻居信息**
  - 定位也是**逐步完成**，每跳选中当前节点路由表中**离目的节点最“近”的邻居**作为下一跳

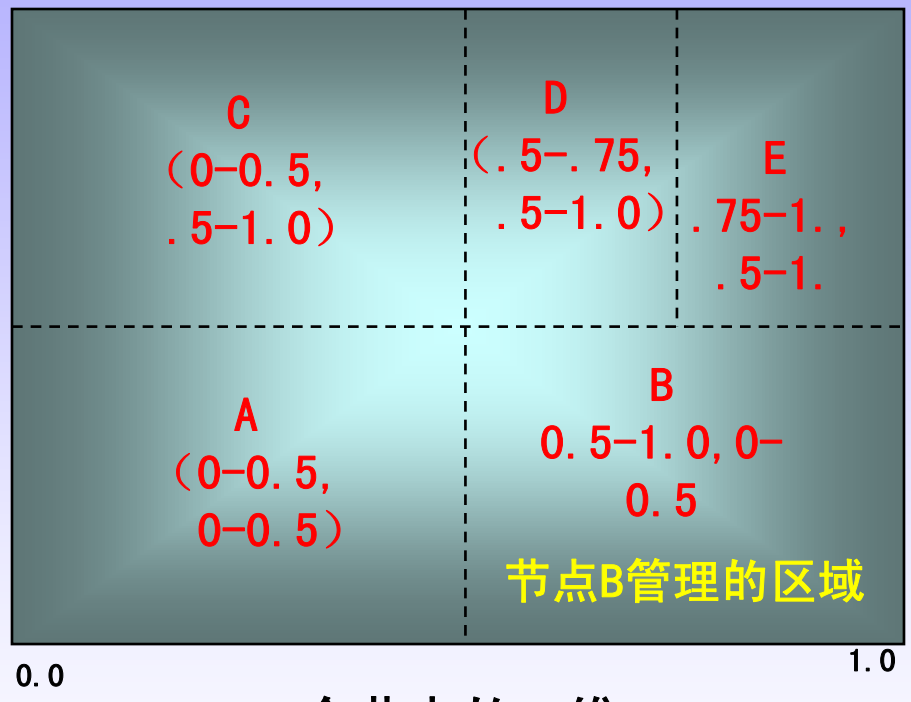

5个节点的二维CAN

CAN网络的构建

- 新节点加入
  - Join1自举：
    - 新节点n找到一个已在CAN节点，如通过CAN的DNS获得举荐者的入口IP地址
  - Join2寻找区域：
    - n随机选择CAN空间一点P，通过举荐者向P发加入请求，并达到P区节点n’
    - n’把区一分为二，先横后纵，分给n，相应数据对象也转给n
  - Join3加入路由表：
    - n从n’获得邻居信息
    - 通知邻居改变路由表以反应n加入的变化
- 自适应
  - 当节点插入、离开或周期更新
  - 自动向邻居发己区路由表信息
  - 0(2d)邻居，开销是O(2d)

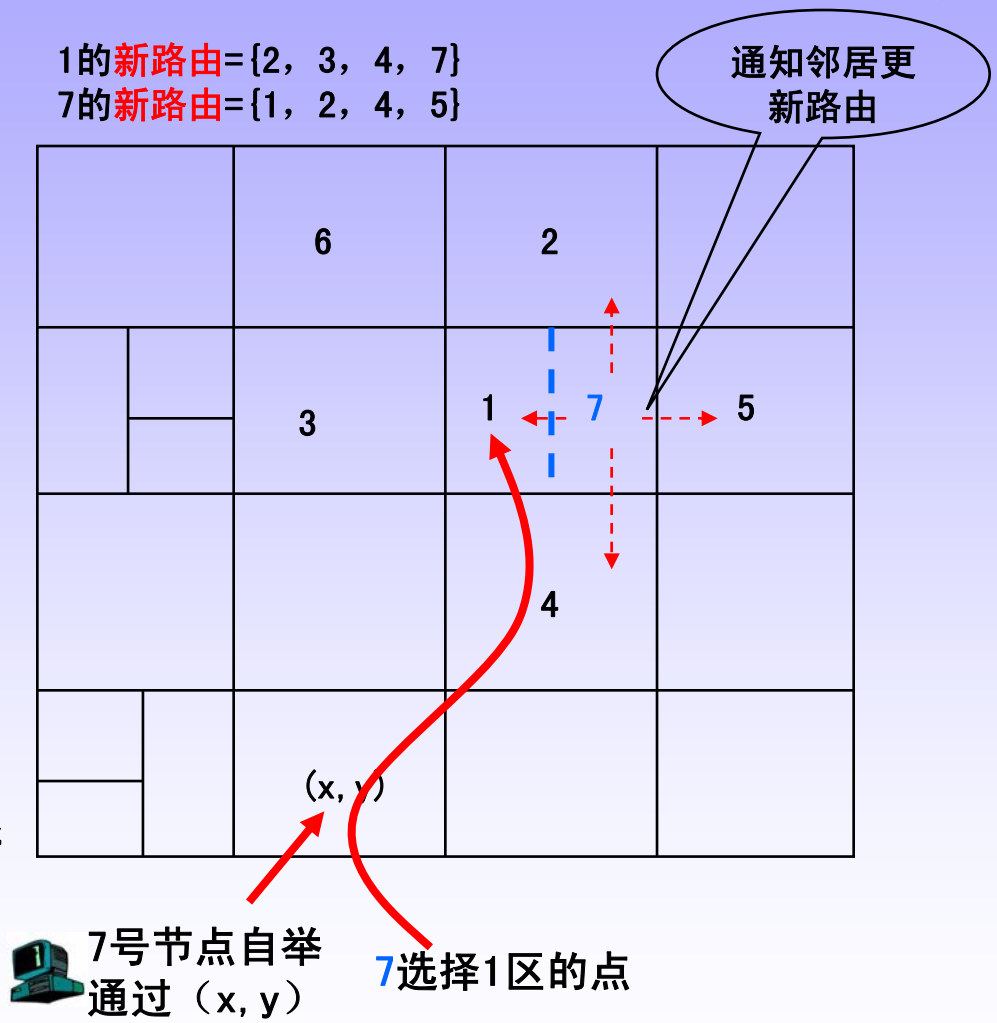

CAN Example

- Space divided between nodes
- All nodes cover the entire space
- Each node covers either a square or a rectangular area of ratios 1:2 or 2:1
- Example:
  - Assume space size (8 x 8)
  - Node n1:(1, 2) first node that joins → cover the entire space

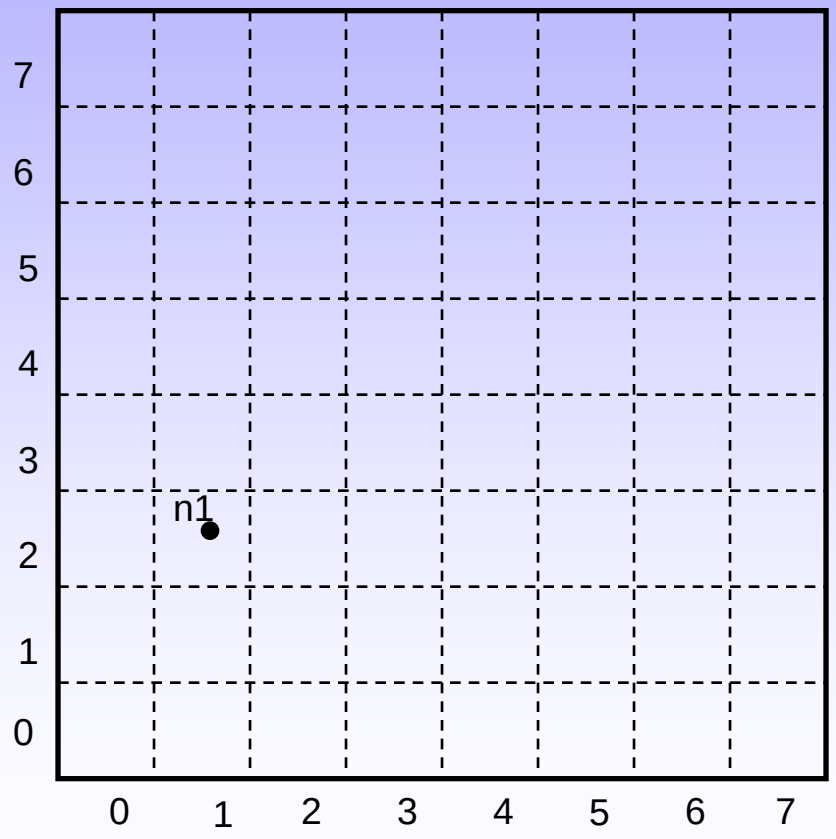

CAN Example:join

- Node n2:(4, 2) joins
  → space is divided between n1 and n2

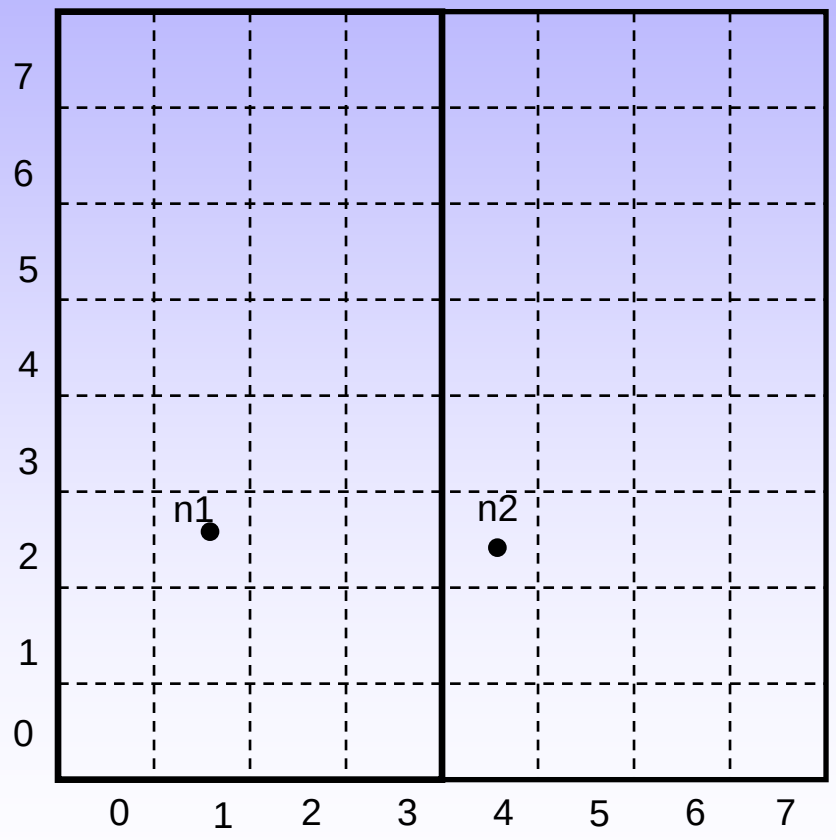

CAN Example:join

- Node n3:(3, 5) joins → space is divided between n1 and n3

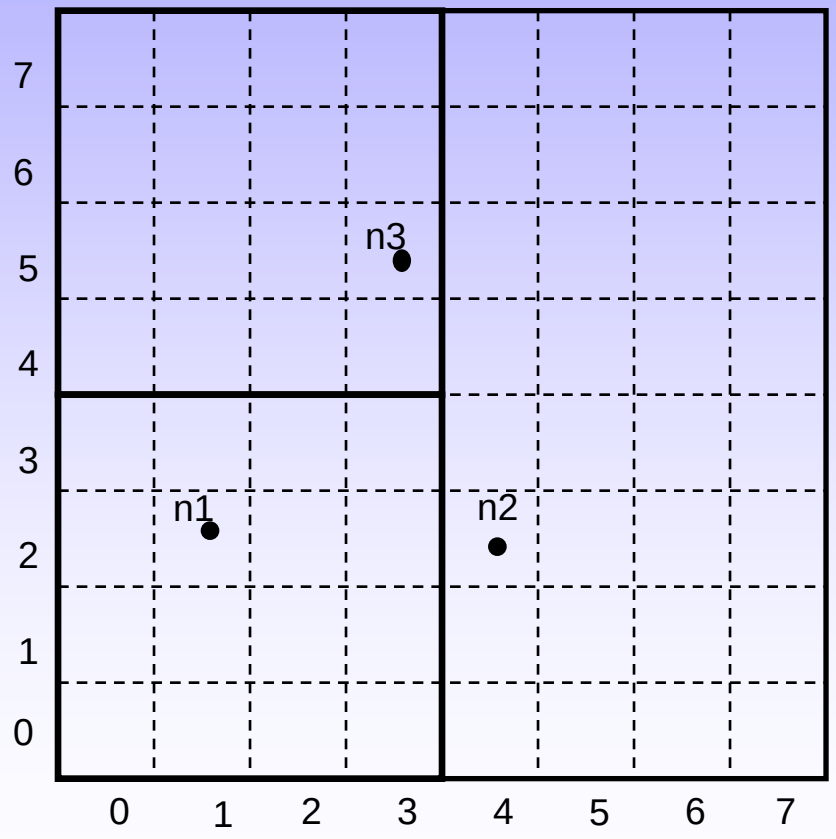

CAN Example:join

- Nodes n4:(5, 5) and n5:(6,6) join

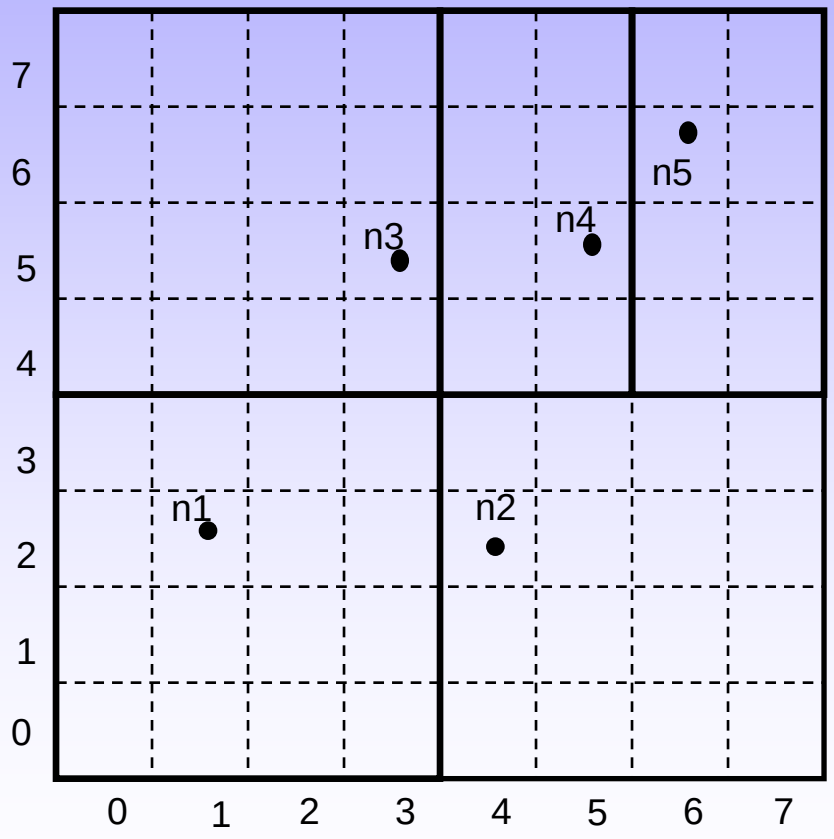

CAN Example:join

- Nodes: n1:(1, 2); n2:(4,2); n3:(3, 5); n4:(5,5);n5:(6,6)
- Items: f1:(2,3); f2:(5,0); f3:(2,1); f4:(7,5);

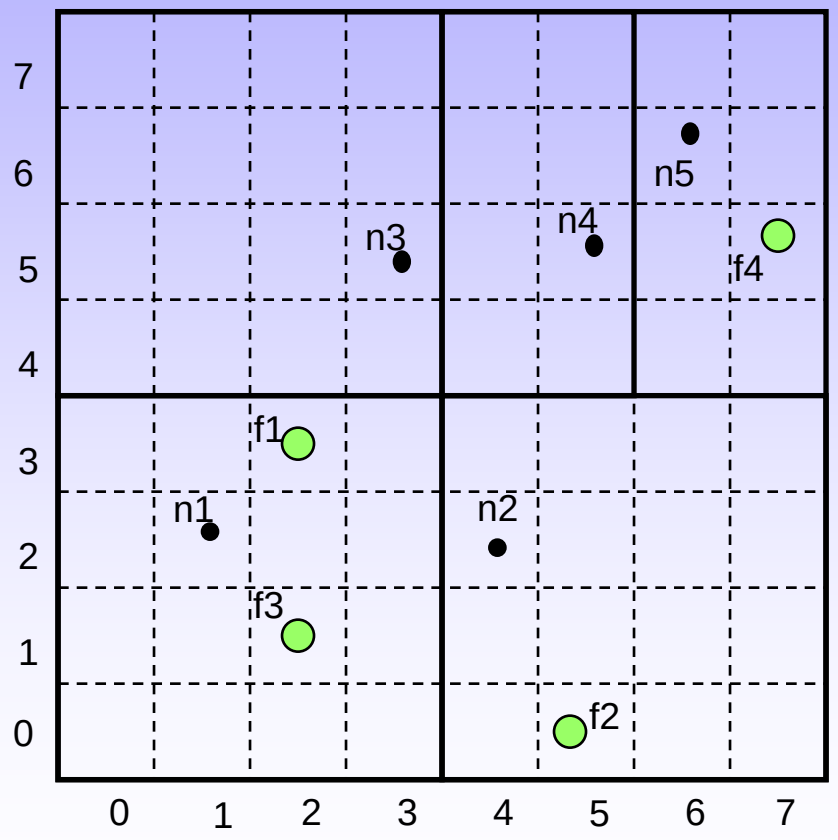

CAN Example:bandle

- Each item is stored by the node who owns its mapping in the space

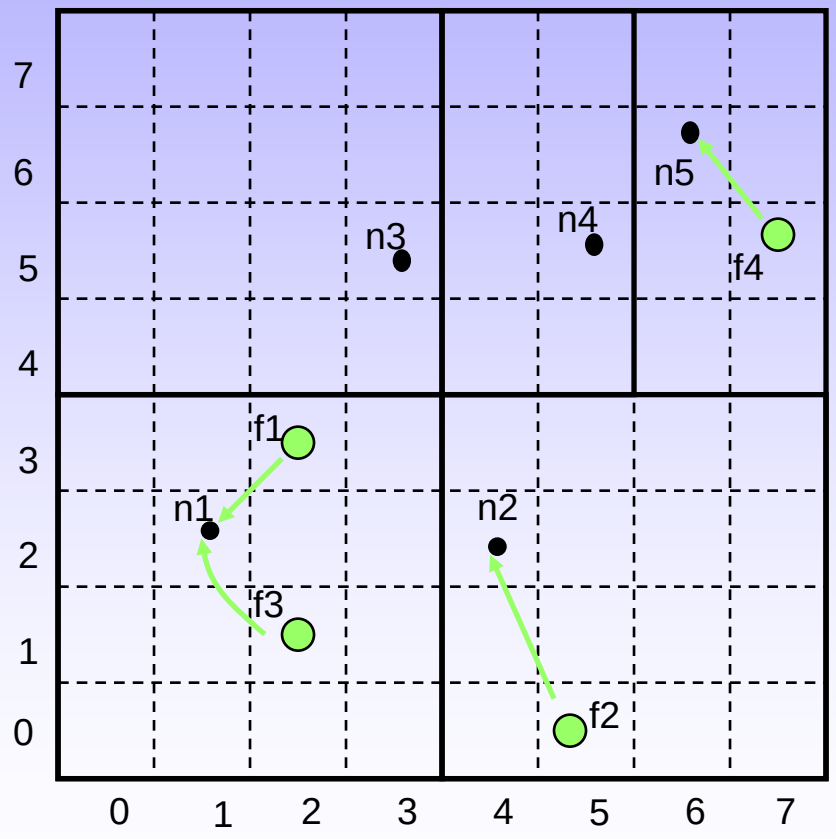

CAN Example : Query

- Each node knows its neighbors in the *d*-space
- Forward query to the neighbor that is closest to the query *id*
- Example: assume n1 queries f4

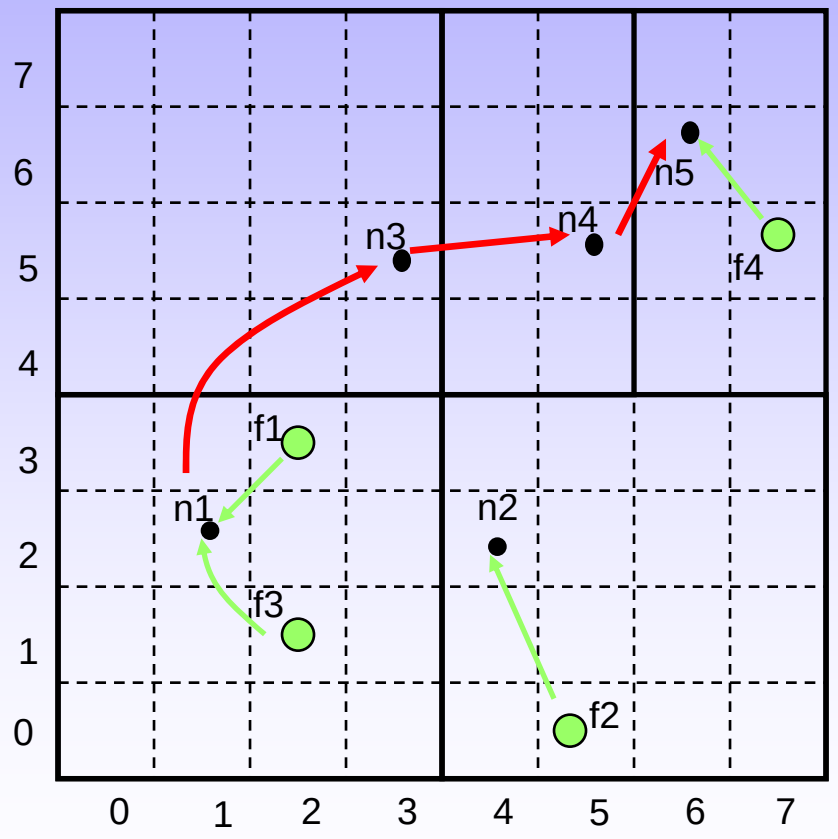

节点的离开与破碎

- CAN节点的离开
  - 正常离开
    - 应把其负责区转交给一邻居，邻居可合并区域；
    - 如不能，则转交给区域最小的邻居，并不合并
  - 动态突发、不辞而别？
    - CAN周期检测在线节点，一旦发现，邻居开始接管
    - 接管后向邻居发 TakeOver；同时接管的多个邻居比较区域大小，最大者取消接管
- 支离破碎问题
  - 随着频繁加入离开，区域划分会破碎
  - 由一个节点负责的区越来越多，超出节点能力
  - 背景区域重分配变规整，区域负责均匀化

CAN增强与总结

- CAN增强机制
  - 多维d：维护路由表2d项，定位效率（路径长）= $O[d\times(N)^{1/d}]$；d增加时，路由表不会增加多少，但路径减小很快，容错也好
  - 多空间：CAN空间只是实际网络的一个逻辑映射，可用多空间来实现，如多份拷贝，提高可用性和效率，可选择最近节点
  - 多散列：多Hash可把同一数据对象分配到多个区域中，多Hash通常在同一数据对象上加入不同的Salt（盐值），映射出不同效果
- 区域超载与复制缓存
  - 区域后维护一个区域超载表，通过减少跳数、延时和复制解决
  - 把数据显式复制到邻居区域中
- 总结
  - 简单直观，每个节点维护2d邻居信息，定位跳数$O[d\times(N)^{1/d}]$
  - 高容错

- Virtual Cartesian coordinate space: d-dimensional torus
- Associate to each node and item a unique *id* in an d-dimensional space

- Entire space is partitioned amongst all the nodes
  - every node "owns" a zone in the overall space

- Properties
  - Routing table size O(*d*)
  - Guarantees that a file is found in at most $O(d \times \sqrt[d]{N})$ steps
  - where *N* is the total number of nodes

4.4.4 Tapestry

- 背景
  - 2000.3,UC Berckeley's Ben Y.Zhao等开始开发，2003.6发布Tapestry2.0，JAVA编写/Linux；应用广泛，著名例子UC Berckeley's OceanStore广域存储系统
  - 基于Plaxton Mesh覆盖网络结构的非严格"超立方体结构"
- 定位与路由:任何网络须考虑的三大问题
  - locating(名→址），routing，topology
  - 名：每个节点/数据对象有全局唯一nodeID,和唯一objectID
  - 绑定：每数据对象分配一负责它的节点→成为该对象的"根"root
    - If 恰好某节点的nodeID==objectID; then root(objectID)= nodeID;
    - Else root(objectID)= 最接近objectID的nodeID
  - 路由：后（前）缀匹配：XXX8→XX98→X598→4598(4598的匹配)
    - 每节点维护一层次化路由表（邻居表），每层代表与自身nodeID匹配一定位数后缀的节点
    - 基于后缀的路由

单个Tapestry节点的路由表

- 8进制4位路由表（1732节点的）
  - 每列称为一层，从右往左第1/2/3/4，表示分别匹配第0/1/2/3位
  - 第i层第j项（0—7共8项）表示当前nodeID后缀匹配为i-1位，且以j开头的节点，如ij(3，5)=x532表示与当前节点1732匹配后2位32，并以5开头的节点

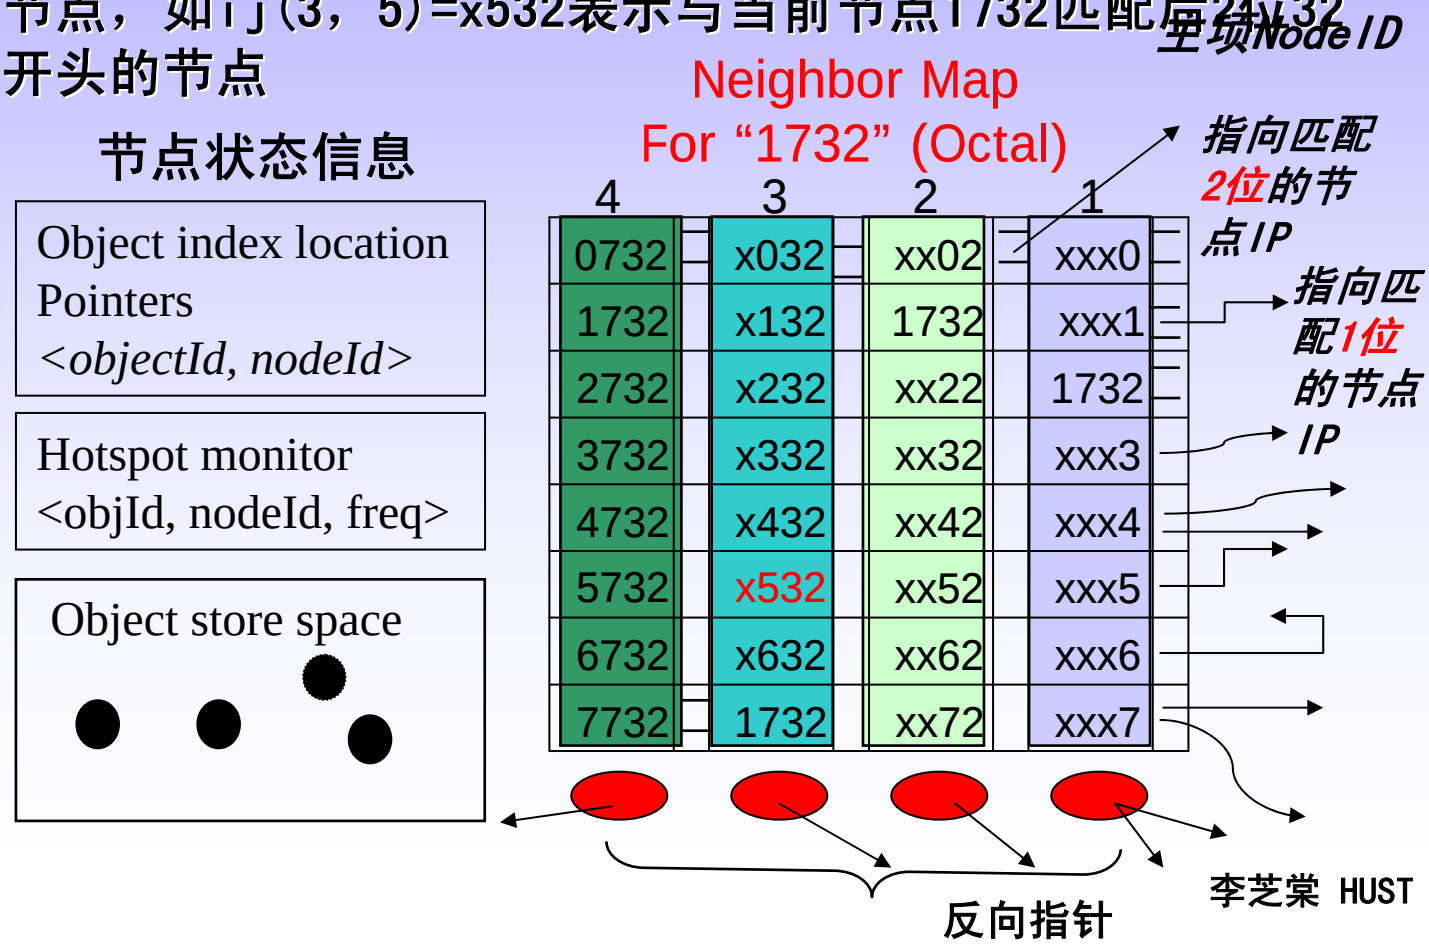

Tapestry 路由过程：0325⇒4598

- 节点0325要发送一条消息给目的节点 nodeID=4598
- 路由过程
  - 第1跳匹配第0位'8'
  - 第2跳匹配第1位'98'
  - 第3跳匹配第2位'598'
  - 第4跳匹配第3位'4598'
- 路由算法
  - 若当前节点ID与目标ID后缀匹配刚好n位，
  - 则在路由表第n+1层中找匹配更多位的项；
  - 该项指针指下一跳

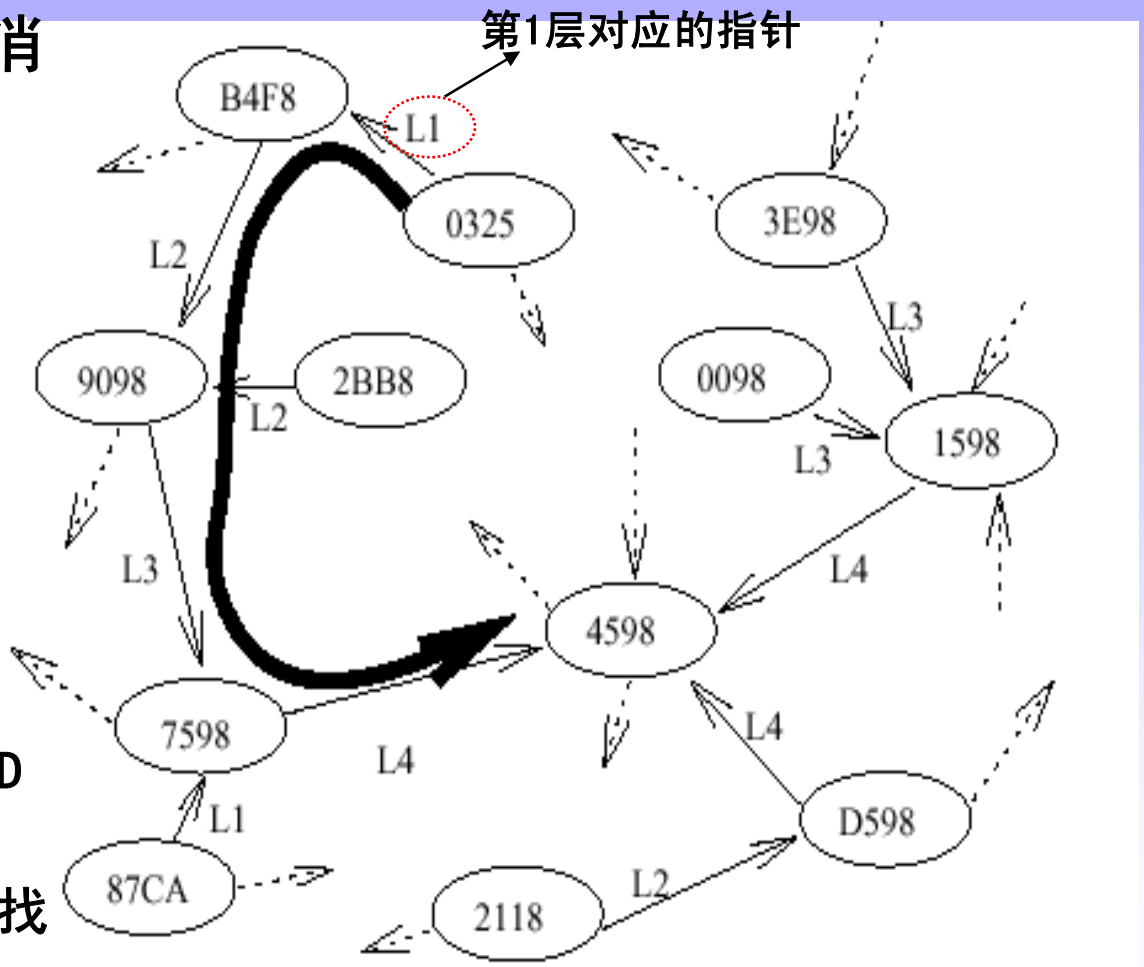

Suffix-based routing

每个节点指派一个根节点

- 根节点：对object*O* *有最长后缀的唯一节点*
  - 根知道 *O* 在何处

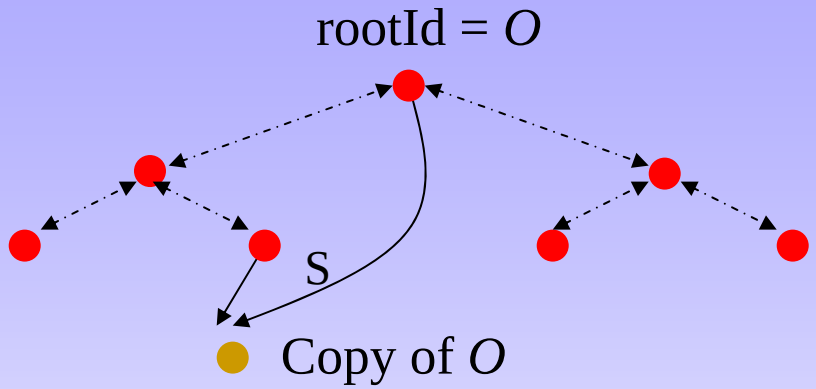

- 发布：节点*S*发送 msg<objectID(*O*),nodeID(*S*)> 到对象*O的根*
- 如果对象O有多分拷贝，就存储在最近的位置
- 定位查询：针对O的消息朝着O's 根路由
- 怎样找到对象的根节点？

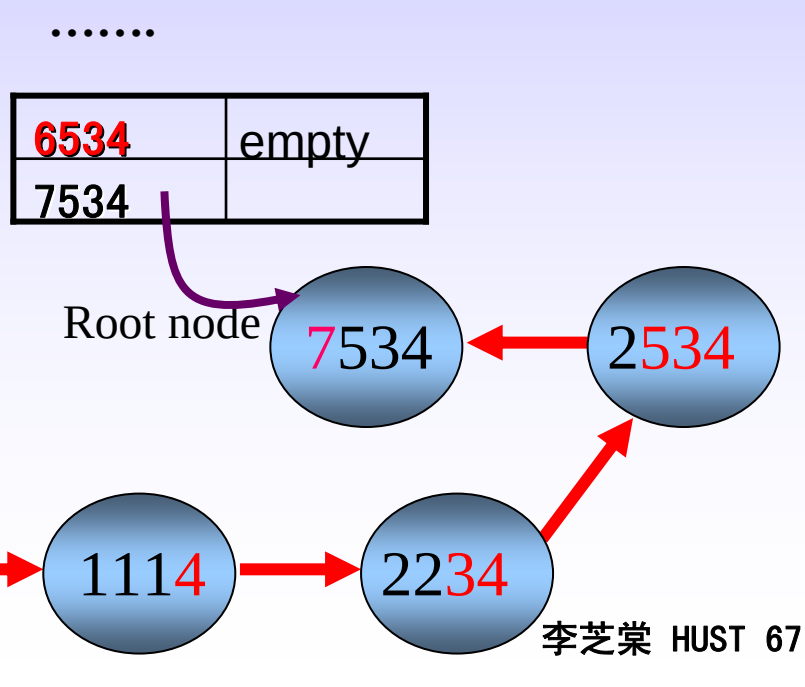

Tapestry动态节点算法

- 反向指针（Back Pointer）
  - 路由表中有反向指针项，指向那些把自己作为路由表项的点
  - 利用BP周期性发送心跳（Heartbeat）消息给反向节点，宣告自己的存在，若一段时间内收不到则认为该路由表项失效
- 路由表中每项保存一个主项、和两个次项
  - 当主项节点失效时，就使用次项节点
  - 两次检测到失效后才替换路由表项，以防止“闪断”现象
- 节点的加入
  - 初始化路由表：新节点N通过现存节点G发送以N自己为目址的消息
  - 设第j步达到节点Hj，初始时H0=G；依后缀匹配算法，N和Hj共享长度j的后缀，故N从Hj那里获得路由表的第j+1层是适合的
  - 路由表优化：对每项，若次要节点对N来说比主项节点更近，则次项变主项；找新主项节点路由表相关项，比较N到每项的距离...收敛

- 更新其它路由节点表
  - N通过G经logN跳内最终达到N的根节点R
  - R收到消息后，计算出与N匹配的后缀位数p，
  - 通过反向指针告诉那些与R也匹配p位后缀的反向节点：
    - 如果N对自己是适合的，则在自己的路由表中添加N或用N替代原来的项
    - 将对象索引中应该由N负责的那部分索引移交给N
- 正常离开
  - 告诉自己的反向节点在路由表中删除节点N
  - 节点N把自己负责的对象索引移交给它们的新根节点
- 非正常离开
  - 则通过周期性检测来发现失效和删除

Tapestry的体系结构

- 3个重要的接口函数
  - Deliver(ID,AID,Msg):接收到要发往ID的消息Msg，当前节点是路由的终点
  - Forward(ID,AID,Msg):将以ID为目址的消息Msg往前传，它通过Route(...)完成
  - Route(ID,AID,Msg,NextHopNode):将以ID为目址的消息Msg路由到下一跳节点
- 说明
  - Id指nodeID或objectID
  - AID代表某种应用类型
  - 应用并不限于右图3类

单Tapestry节点组件结构

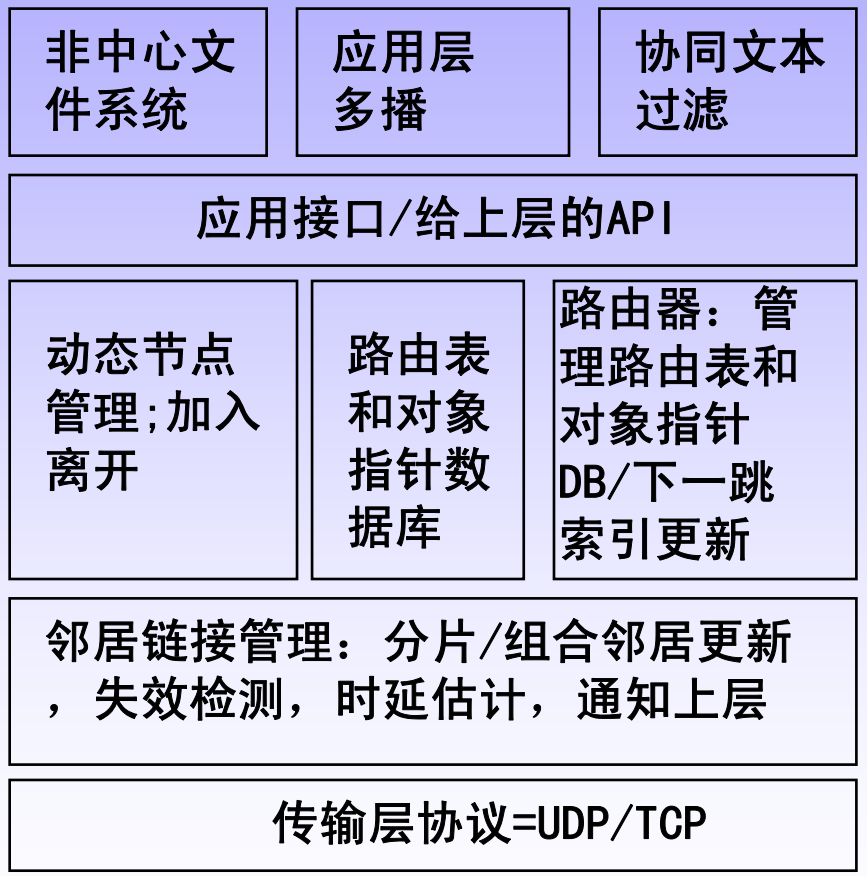

Tapestry 总结

- 是一个分布存取、容错的超立方体结构P2P模型
- 每个节点、数据对象和应用都有全局唯一ID，每个数据对象有一个负责它的节点（根），根是nodeID与objectID最匹配的节点
- 在N个节点的网络中，任何一次定位都能在$Log_B(n)$ 跳内完成 n≤N 是实际物理网的节点数。B为ID编码的进制，如B=8
- 共有$Log_B(n)$ 层，每层有B项，故总表有$BLog_B(N)$
- 反向指针可用于节点加入、离开、失效检测和修复
- 5层体系结构，支持很多应用，典型有
  - 文件分布式系统：OceanStore
  - 应用层多播：Bayeux
  - 协同文本过滤：SpamWatch

4.4.5 Pastry/PAST

- 背景
  - 2000年，Microsoft Research,Rice University's Antony Rowstron and Peter Druschel设计开发，现有两个版本
    - Rice University's开发的FreePastry
    - Microsoft Research开发的SimPastry/VisPastry
  - 著名应用是PAST归档存储系统
- 概况
  - 容错、高效、可扩展的混合式结构P2P网络
  - 结合环形结构和超立方体（Plaxton Mesh）结构的优点,提供高效查询路由、确定性的对象定位和独立于应用的负载均衡
  - 提供复制、缓存和错误复原等增强机制

Pastry: hypercube connection

如何维持某些节点缺席时的超立方体连接：所有活动节点维持3个联系邻居

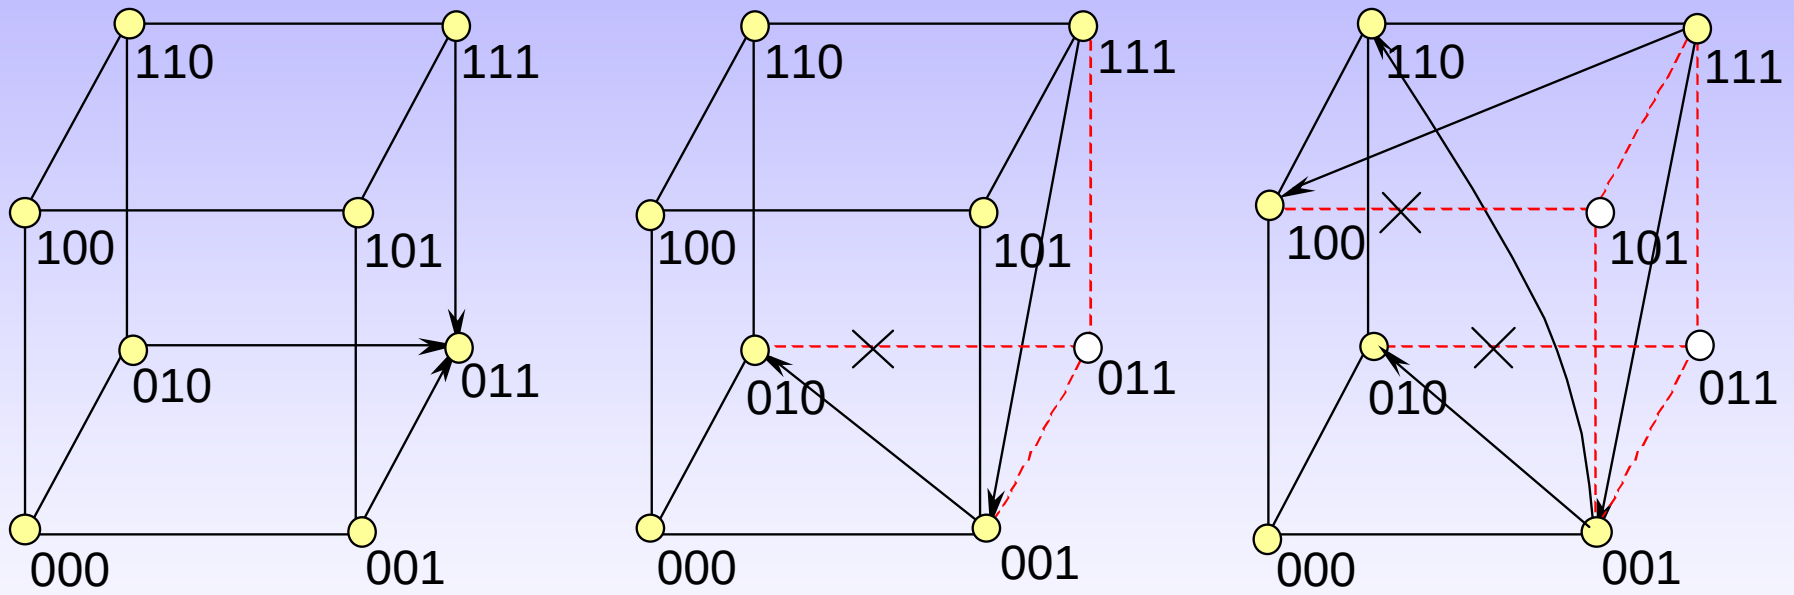

(a)传统超立方体　(b)节点011失效后的可重构　(c)节点101再失效后的可重构

Pastry的路由

- Hash128位/均匀/唯一ID
  - nodeID独立于节点属性，以标识网络覆盖
  - objectID,对象索引由与objectID最近的nodeID节点负责
  - 采用前缀匹配
- 每节点维护一右图路由表R
  - 4进制8层路由表
  - 从上至下第0,1..7行，分别代表与当前nodeID匹配第0，1..7位前缀的节点
  - 每行4项从左至右以0,1,2,3开头
  - 与当前nodeID在该位恰等的项标为阴影（10233102）
  - nodeID以X-Y-Z形式便于观看
    - X:匹配的前缀，第0行无X
    - Y:第一个不匹配位
    - Z:ID的后几位

NodeId 10233102

Leaf set

SMALLER		LARGER	
10233033	10233021	10233120	10233122
10233001	10233000	10233230	10233232

Routing table

-0-2212102	1	-2-2301203	-3-1203203
0	1-1-301233	1-2-230203	1-3-021022
10-0-31203	10-1-32102	2	10-3-23302
102-0-0230	102-1-1302	102-2-2302	3
1023-0-322	1023-1-000	1023-2-121	3
10233-0-01	1	10233-2-32	
0		102331-2-0	
		2	

Neighborhood set

13021022	10200230	11301233	31301233
02212102	22301203	31203203	33213321

- 每节点维护一叶集L
  - 包含|L| 个与当前nodeID最邻近的“叶节点”
  - 其中|L|/2个比当前节点ID小的叶节点， |L|/2大的节点
  - 作用在于保证路由正确性，类似Chord的后继节点表
- 每节点维护一邻居集M
  - 包含|M|个网络物理层与当前节点邻近的节点
  - 以增强工作的局部性，通常不使用
- 节点状态
  - 状态数= L+R+M
  - 表项数=$|L|+B\log_B N+|M|$;

- 路由算法
  - 每步至少比前一步多匹配1位前缀，直到无法再匹配更多位
  - 即寻找当前节点的叶节点集中与目的ID的最接近的节点
  - 符号说明
    - A：当前节点ID，D：目的节点ID
    - R^i_j：R中第j行的第i项
    - L_i：叶集L中离当前节点ID第i近的节点
    - D_j：D的第j位
    - shl(A,B)：A、B匹配的前缀长度

If D 位于叶集范围内

forward to L_i;$|D-L_i|$最小者

Else利用R {

j=shl(D,A);求匹配前缀长度

if($R^{Di}_j \neq$null) forward to R^{Di}_j

else forward to $T \in L \cup R \cup M$

shl(T,D)≥j;极少出现

|T-D|<|A-D|；扩大路由

Routing 算法

```
(1)  if (L_{-⌊|L|/2⌋} ≤ D ≤ L_{⌊|L|/2⌋}) {
(2)      // D is within range of our leaf set
(3)      forward to L_i, s.th. |D − L_i| is minimal;
(4)  } else {
(5)      // use the routing table
(6)      Let l = shl(D, A);
(7)      if (R_l^{D_l} ≠ null) {
(8)          forward to R_l^{D_l};
(9)      }
(10)     else {
(11)         // rare case
(12)         forward to T ∈ L ∪ R ∪ M, s.th.
(13)             shl(T, D) ≥ l,
(14)             |T − D| < |A − D|
(15)     }
(16) }
```

(1) Single hop

(2) Towards better prefix-match

(3) Towards numerically closer *NodeId*

D: Message Key
L_i: i^{th} closest NodeId in leaf set
shl(A, B): Length of prefix shared by nodes A and B
R^i_j: (j, i)th entry of routing table

Pastry路由

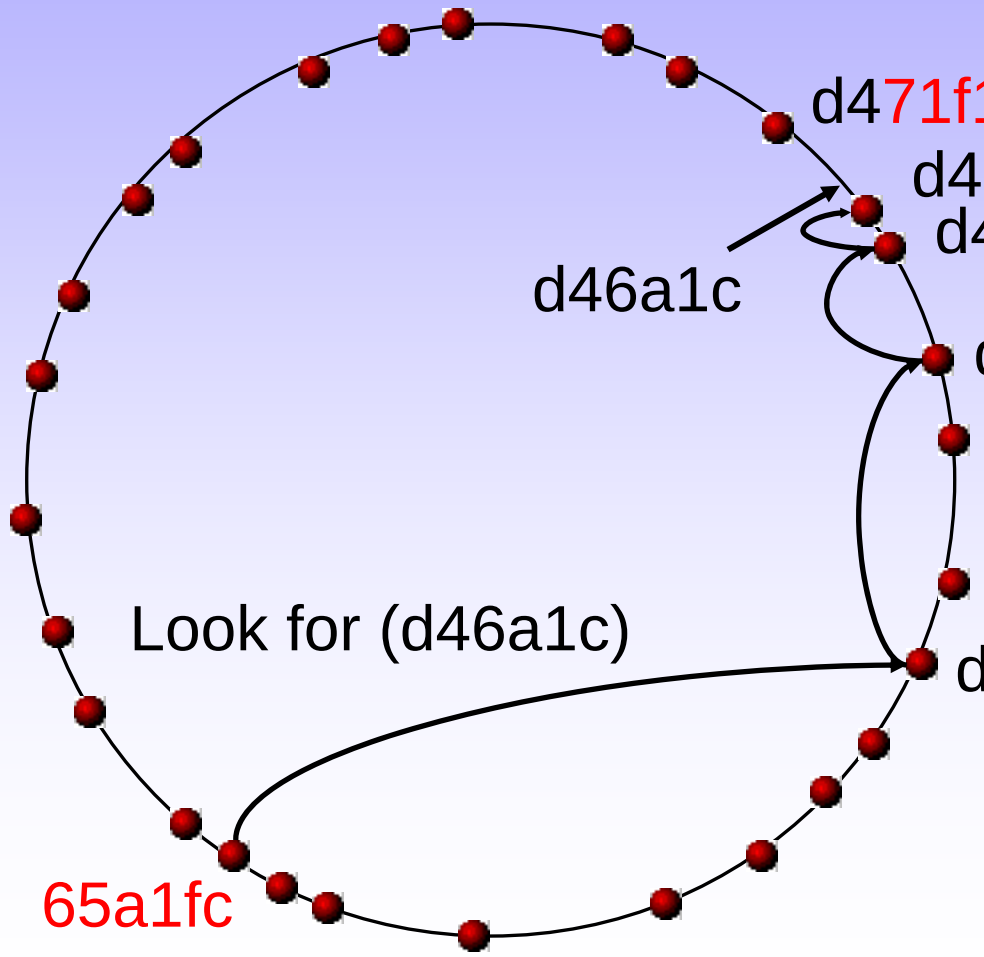

Properties

- $\log_2{}^b$ N steps
- O(*log M*) state

Pastry自组织和自适应

- Join Step1:初始化R/L/M三表
  - 新节点X加入，先通过某种方式联系到现存节点A
  - X通过A发出一条以X为目的地消息
  - 最终达到离X最近的节点Z
- Join Step2:通知其它节点自己的到来
  - X把自己节点信息发给自的R/L/M中节点即可
  - 剩下工作由收到更新消息的节点自己去做
- Join Step3:新节点获取需要负责的数据
  - 从ID最接近（如叶节点）的节点获取数据
- Fail Step1:修正叶集
  - 若某叶节点失效，通过未失效最远节点获取新叶集
- Fail Step2:修正路由表
  - 若R_{ld}失效，发消息给第l行未失效第i项节点（$i \neq d$）
  - 找第l行第d项作为代替项
- Fail Step3:修正邻居集
  - 由于不常用，修正宽松
  - 每个一个月修正
  - 若存在失效邻居，则发消息给未失效邻居获取新的集

Pastry: Node addition

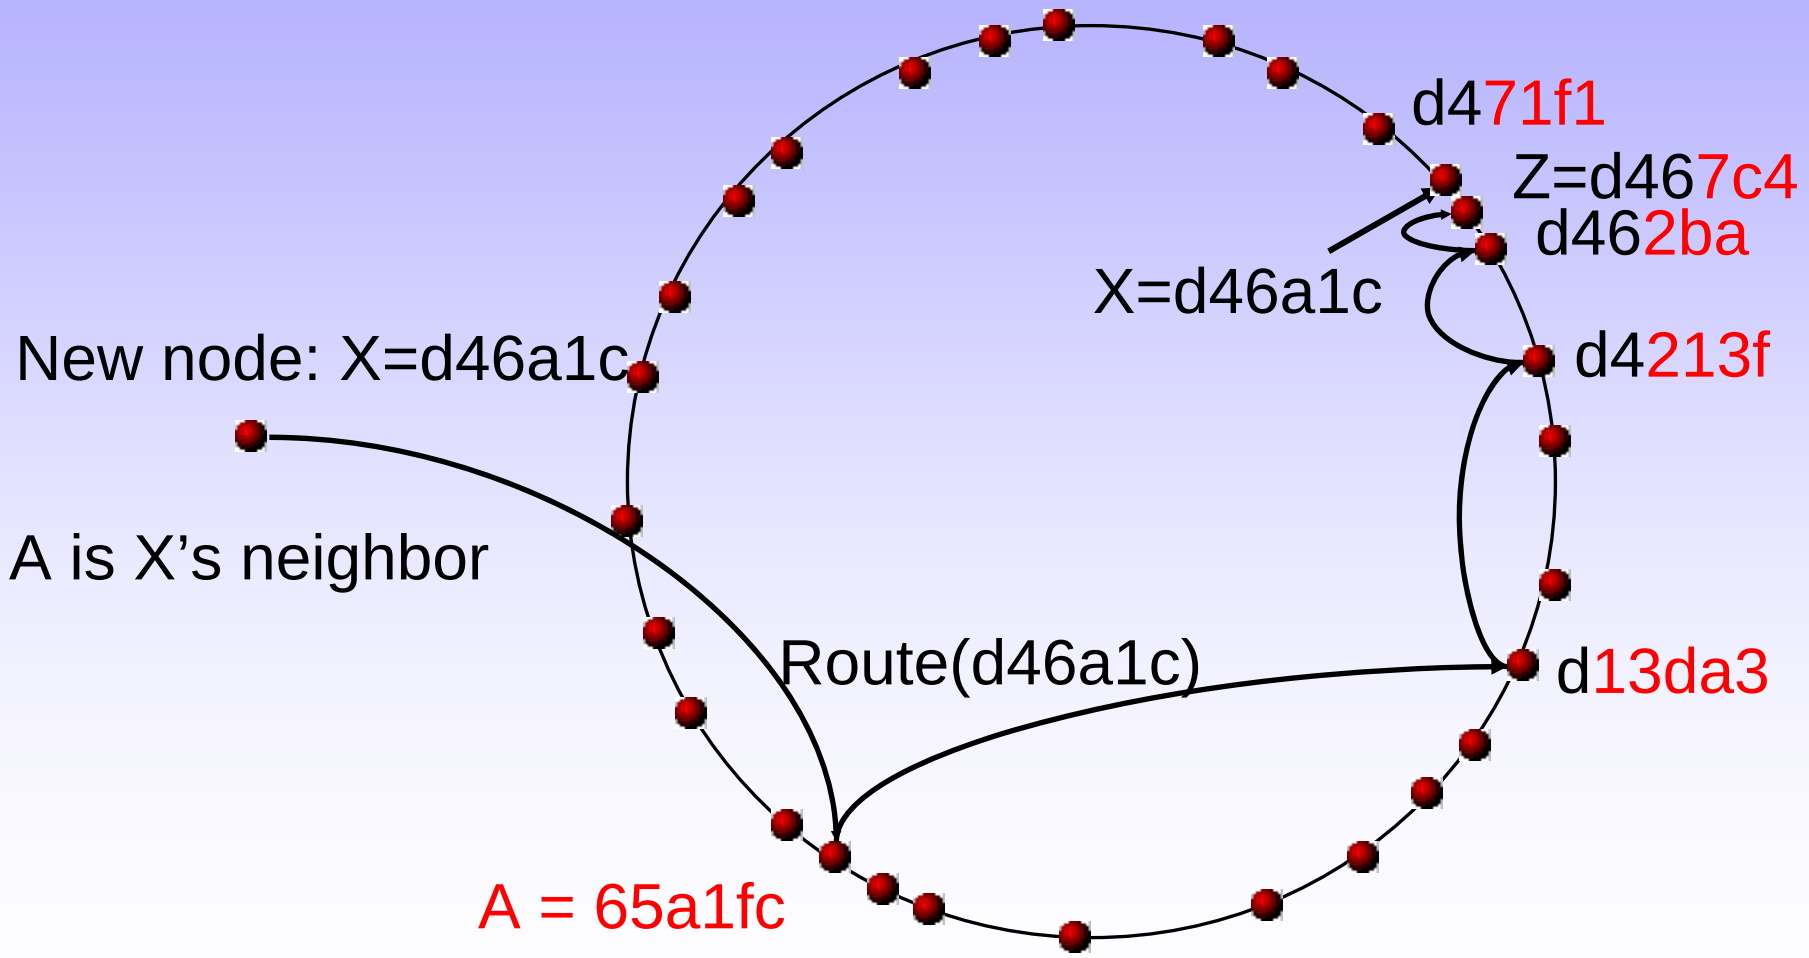

基于Pastry的归档系统PAST

- 广域P2P归档存储系统，提供安全高可用、持久性的数据存储服务
- 向用户提供需要证书合法的插入、查询、回收基本操作，且插入、回收还需“收据”确认
- 每个PAST用户有一权威机构发行的“智能卡”，是安全核心部件
- 存储管理2个目的
  - 不断平衡网络节点剩余的空闲存储空间
  - 保持每个数据对象有k个副本存放在nodeID相近但不同的k个节点上
  - 为此，采用“副本转移”、“文件转移”、“路径缓存”等方法

Pastry总结

- Generic p2p overlay network
- Scalable, fault resilient, self-organizing, secure, IDs are in base 2^b, randomly assigned from {0, .., $2^{128}-1$}
- $O(log_B N)$ routing steps (expected); $B=2^b$
- $O(log_B N)$ routing table size
  - b defines the tradeoff: $(Log_{2b}\ N)\ x\ (2^b - 1)$ entries Vs. $Log_{2b}\ N$ routing hops
- Network locality properties

4.4.6 新型P2P网络Kademlia

I） 基本概念

- 常数度P2P网--理络论上特殊的新型结构化
  - 路由、定位、自组织方式与前4种区别不大
  - 但每个节点的“度”（连接数）是固定的，与规模无关
    - 维护固定路由表项，仍能达到O(LogN)跳的指数定位效率
    - 路由表固定导致网络自适应开销减少
  - 著名常数度网络
    - Vicroy(2002),Koorde(2003),Cycloid(2004)
- 更容错实用的结构化网络Kademlia
  - 路由方法类似Chord
  - 但采用基于XOR的距离度量
  - 将结构配置信息融合到每条消息，从而构建高容错和自适应的P2P新年息系统
- SkipNet模型
  - 2003，微软和华盛顿大学提出，类似Chord
  - 但采用跳表提供节点路由、对象语义两方面的局部性

KADEMLIA简介

- Kademlia协议是美国纽约大学的 Petar P. Maymounkov和David Mazieres 在2002年发布的一项研究结果

《Kademlia: A peer-to-peer information system based on the XOR metric》。

- Kademlia 是一种分布式哈希表（DHT）技术，Kademlia通过独特的以异或算法（XOR）为距离度量基础，建立了一种全新的DHT 拓扑结构，相比于其他算法，大大提高了路由查询速度。

Kademlia

- Chord的缺点
  - 距离度量**不对称**
  - 路由消息**不能反映**有用的网络结构信息
  - 路由表非常严格，后继关系必须为**不变属性**
- Kademlia
  - XOR度量不影响可**扩展性和工作效率**
  - 提供**容错**性和**灵活**性
  - XOR是对称的，从路由消息中可获得有用的网络配置信息
  - “携带更新”的开销提高了自适应性
  - 节点可发消息给其路由表中任意一段（interval）中的每个节点,让它们基于**时延选择路由下一跳**，还可发并行的异步消息

II) 当前应用现状

- 在2005 年5 月著名的BitTorrent 在4.1.0 版实现基于Kademlia 协议的DHT 技术后，很快国内的BitComet和BitSpirit 也实现了和BitTorrent 兼容的DHT 技术，实现trackerless 下载方式。
- 另外，emule 中也很早就实现了基于Kademlia 类似的技术（BT中叫DHT，emule 中也叫Kad，），和BT 软件使用的Kad 技术的区别在于key、value 和node ID 的计算方法不同。

Kademlia协议的应用

所在网络及分野		具体应用说明
Overnet网络	Overnet	已被整合到eDonkey2000中
	eDonkeyHybrid	混合式eDonkey软件
	mlDonkey	运行于多平台，多网络的eDonkey扩展版软件，支持多协议，如BitTorrent, eDonkey, DirentConnet, FastTrack, Gnutella2, FTP/HTTP, Kad, Cvernet, OpenNap, SoulSeek
Kad网络	eMule	开始与0.40版
	mlDonkey	开始于2.5—28版
	aMule	即all-platform eMule，是eMule的扩展版，支持很多OS，开始于2.10
RevConnect		基于DirentConnet协议的P2P文件共享系统，以Kademlia为分布式Hash，能多源下载，部分文件共享，安全用户认证，自动资源回收、增强的自动搜索等功能，开始于.404版
KadC		用以在Overnet网络中发布、获取信息的C语言库
Azureus		开始于2.3.0.0版，使用Kademlia网络作为BitTorrent Trackers失效是的替代定位方法
BitTorrent		其Beta 4.1.0版拥有一个Kademlia网络，为无Trackers的Torrents服务
BitSpitit		基于BitTorrent协议的一个客户端，开始于3.0版
eXeem		基于BitTorrent网络的一个P2P文件共享软件，目的是取代BitTorrent中原有的Trackers，开始于Beta 0.25版

III) 节点间的异或距离

- 定义两个节点x,y（ID值表示）的“异或”距离（非欧距离）
  - 节点与数据对象都用SHA-1分配160 Bits ID，
  - 对象索引由与objectID最接近的nodeID负责，“最接近”由XOR距离度量
  - d(x,y)=x⊕y，如1011⊕0010=1001=9 ＞ 1011⊕1010=0001=1
- 异或距离的性质：
  - 合理性： d(x,x)＝ 0
  - 非负性： d(x,y)≥ 0
  - 对称性： d(x,y) ＝ d(y,x) ，对任何x,y,且 x≠y.Chord不具备
  - 三角不等式： d(x,y)+d(y,z)≥ d(x,z)
    - 因为d(x,z) ＝ d(x,y)⊕d(y,z)
    - 对任意 a≥0, b≥0 , a+b≥ a⊕b
  - 单向性：任意节点x和距离d，系统中仅有唯一节点—y满足d(x,y)=d
    - 单项性保证相同数据对象的定位最终将会汇聚于相同的路径
    - 越往后走汇聚可能性越高，于是路径缓存可提高定位效率
  - 传递性：显然 if d1≥d2 and d2≥d3 ,then d1≥d3 成立

- 异或距离结构性好处
  - 按当节点ID与所有其它节点ID间XOR距离大小排队，当知目标结点ID后，就很容易计算出目标节点在这条长队中的位置；
  - 如果给定一个异或距离，你也能很容易从这条长队里找出与该距离最接近的那些结点
  - 节点0011实现了与自身前缀相似度越高的结点离自己越近
- 异或求距离

```
      010101
XOR   110001
--------------
      100100 = 32＋4＝36。显然，高位更容易影响距离
```

IV) K-桶路由表

- K-buckts：每节点维护一个路由表，它由logN个k桶构成
  - 实质是一个链表集，每节点 0≤i＜160个桶，每个桶的大小分理论上依此为：2^i(0≤i＜160)；每桶记录=（序号i，到自己的异或距离2^i—2^{i+1}，节点信息）
  - 节点信息 = <拥有者IP，下载端口，拥有者节点ID >三元组
  - 表项以访问时间排序，最近（least-recently）看到的放在头部，最远（most-recently）看到的放在尾部
  - Kad网络是靠UDP协议交换信息

I	距离	邻居
0	$[2^0,2^1)$	(IP address,UDP port,Node ID)$_{0\text{-}1}$ ..... (IP address,UDP port,Node ID)$_{0\text{-}k}$
1	$[2^1,2^2)$	(IP address,UDP port,Node ID)$_{1\text{-}1}$ ..... (IP address,UDP port,Node ID)$_{1\text{-}k}$
2	$[2^2,2^3)$	(IP address,UDP port,Node ID)$_{2\text{-}1}$ ..... (IP address,UDP port,Node ID)$_{2\text{-}k}$
.....		
i	$[2^i,2^{i+1})$	(IP address,UDP port,Node ID)$_{i\text{-}1}$ ..... (IP address,UDP port,Node ID)$_{i\text{-}k}$
.....		

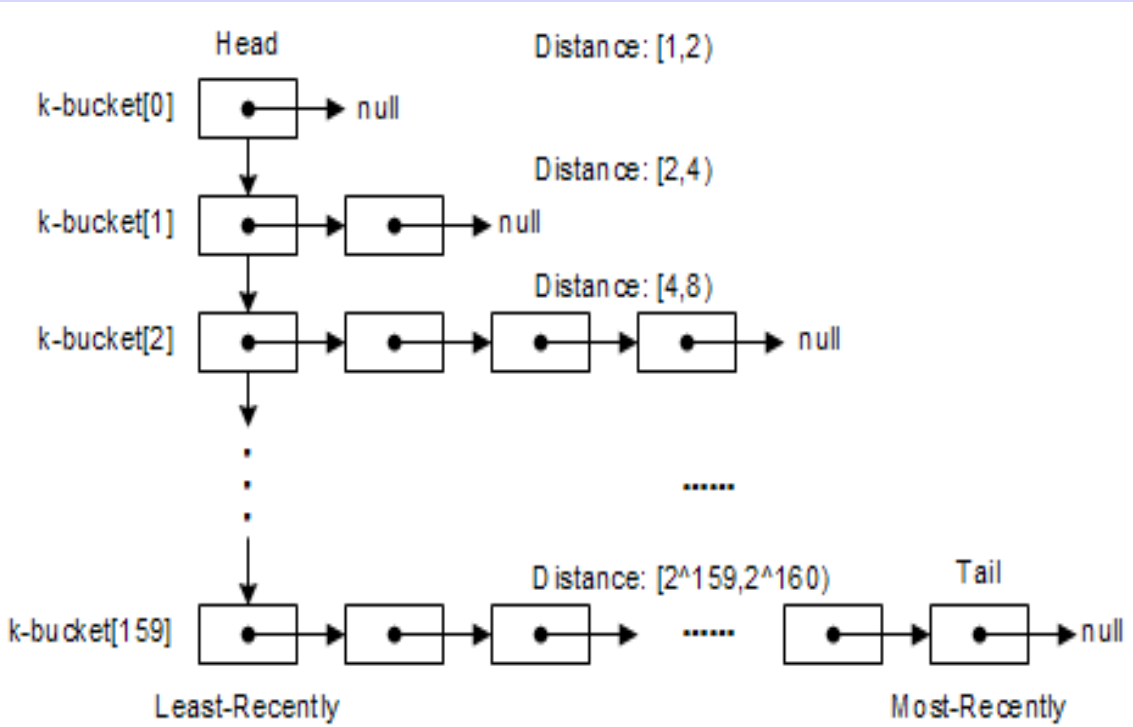

- Interval：间隔大小
  - 对很小i，其链表常为空,即与自己很近的本地节点难找到
  - 对很大i，需记录的节点数随i指数增加
  - 限制表项增长,上限为k，一般偶数，emule=10，OverNet=20,BT=8
- Kad路由表是一颗二叉树
  - 叶节点为K 桶，存放有相同ID 前缀的节点信息
  - 这个前缀就是该K 桶在二叉树中的位置
  - 每个K 桶都覆盖了ID 空间的一部分，全部K 桶的信息加起来就覆盖了整个160bit 的ID空间，且不重叠
- K桶覆盖范围呈指数增长
  - 这就形成了离自己近的节点的信息多，离自己远的节点的信息少，从而可以保证路由查询过程是收敛。
  - 指数划分区间，对有N 个节点的Kad网络，最多只需要经过logN步查询，就可以准确定位到目标节点。

子树的划分或K桶的分裂过程

- 所有节点都被当作一颗二叉树的叶子，且每个节点的位置都由其ID值的最短前缀唯一的确定。
- 任一节点，都可以把这颗二叉树继续分解为一系列连续的，不包含自己的子树
- 最高层子树，由整颗不包含自己的树的另一半组成
- 下一层子树由剩下部分不包含自己的一半组成；
- 依此类推，直到分割完整颗树。

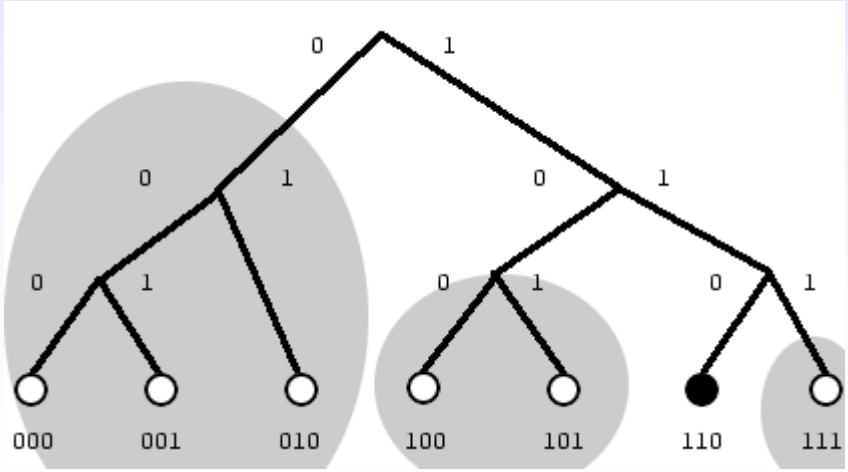

节点0100的K-BUCKET分裂过程

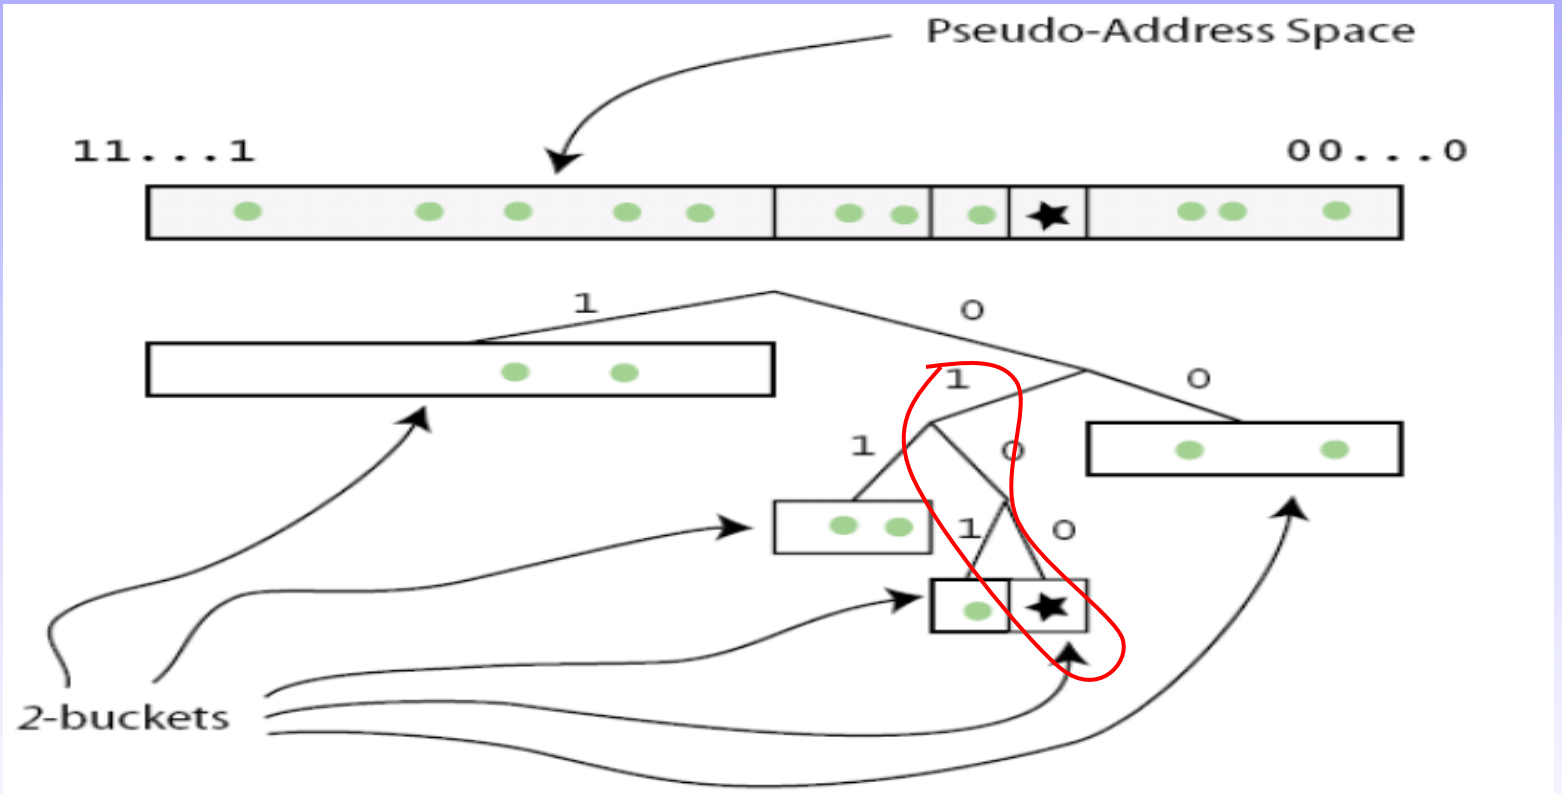

对于一个有N 个节点的Kad网络，最多只需要经过logN步查询，就可以准确定位到目标节点。这个特性和Chord 网络上节点的finger table 划分距离空间的原理类似。

节点0011子树的划分

- 虚线包含部分都是0011看到的子树
  - 由上到下各层的前缀分别为1，01，000，0010
  - Kad确保每个节点**知道其各子树的至少一个节点**，只要这些子树非空
  - 因此，每节点都可以通过ID值来找到任何一个节点。这个路由的过程是通过XOR距离得到

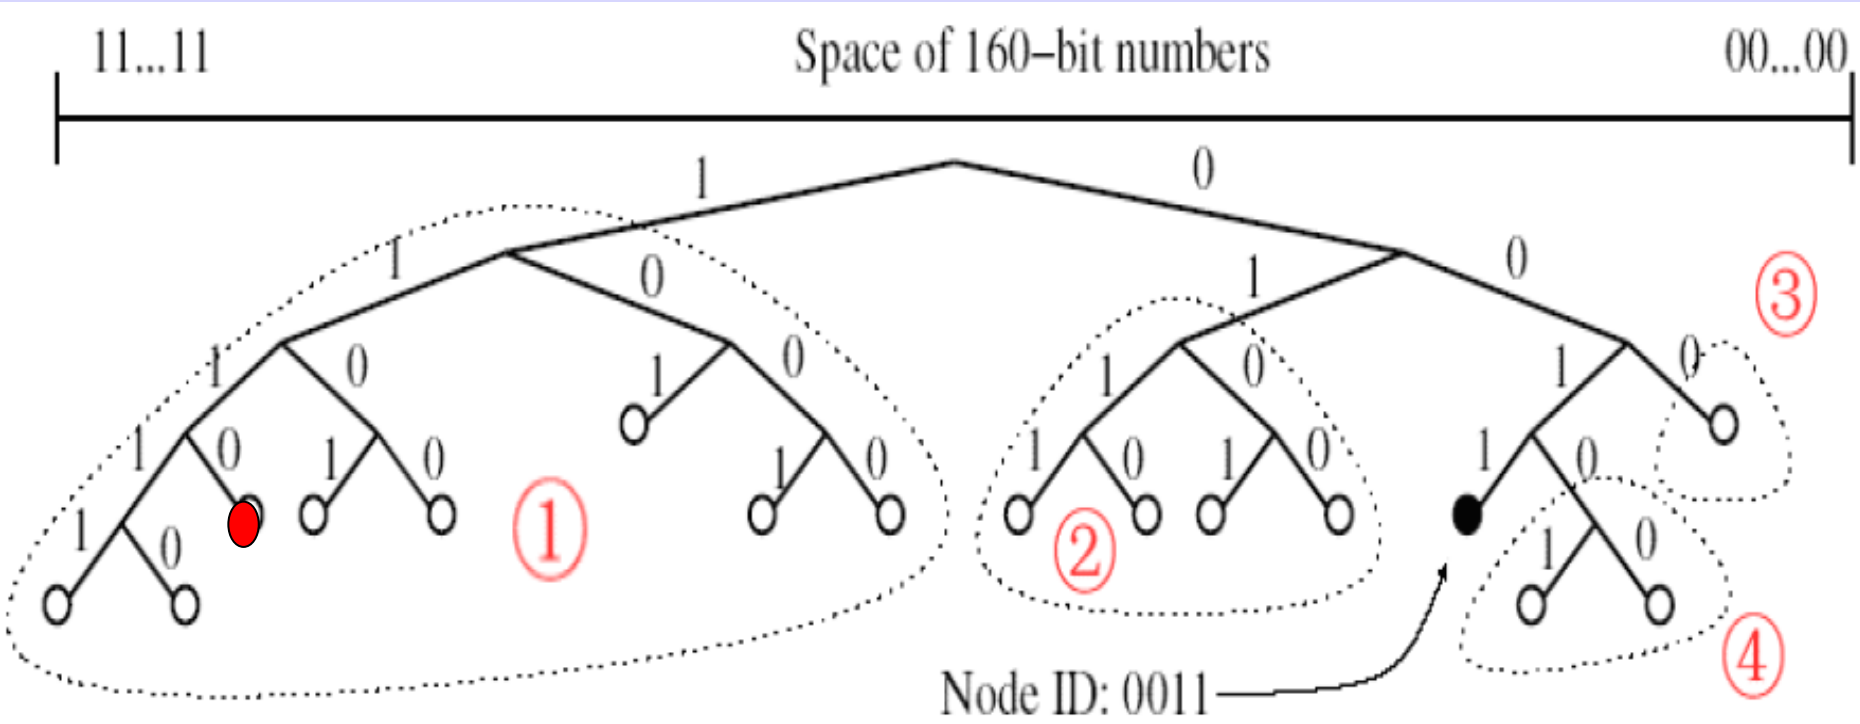

V) 节点的本地行为

节点初始化

- Kademlia读取本地配置文件
  - src_index.dat,key_index.dat load_index.dat（索引）
  - nodes.dat（上次程序启动时连接上的节点 RoutingZone.cpp）
  - preferencesKad.dat（上次程序启动时本地节点IP、ID、Port）
- 生成ID
  - 根据特定信息Hash或随机生成160位ID
- 构造本地结点二叉树
  - 所有节点都被当作一颗二叉树的叶子，位置都由其ID值的最短前缀唯一确定
  - 每个节点都在本地维护一个二叉树,来标示网络中节点与自己的距离远近,自己则是二叉树的根节点；
  - 本地结点二叉树生成规则：
    - 最高层的子树，由整颗树不包含自己的树的另一半组成；
    - 下一层子树由剩下部分不包含自己的一半组成；
    - 依此类推，直到分割完整颗树。

新结点的加入

- 新节点u必需首先获得一个已经在网络中的结点w的contact信息；
- u 首先将 w 插入到其对应的 k-bucket 中；
- u 执行一个对自己id的 FIND_NODE 操作；根据收到的信息更新自己的K 桶内容
- u对自己邻近节点由近及远的逐步查询刷新所有的 k-bucket；（刷新算法）
- 同时也把自己的信息发布到其他节点的K 桶中

VI) 节点间的交互行为

- Kademlia协议包括四种远程RPC操作
  - PING：探测一节点，判断其是否仍然在线。并在回应中携带网络地址
  - STORE：指示一节点存储一个<key , value>对，以便查找
    - key 是对象的hash值，即objectID
    - Value是真正的数据对象或其索引
  - FIND_NODE：以160bit ID 作为参数。本操作的接受者返回它所知离目标ID最近的K 个节点的(IP address ,UDP port , Node ID)三元组信息
  - FIND_VALUE：以key为参数寻找key对应的value.
    - 同FIND_NODE，但需返回一个节点的(IPaddress , UDPport , NodeID)
    - 若接受者已收到同一key 的STORE 消息，则只直接返回存储的value 值。
    - 为缓存，成功找到value 用户将<key , value>存储在它所知离key最近，但未返回value的节点中
- Piggyback确认捎带
  - 所有RPC 都带一160 bit随机 RPC ID，由发送者产生，
  - 接收者返回消息里面必需拷贝此 RPC ID。目的是防止地址伪造。

更新K-BUCKET

- x←y 消息，则更新与d(x,y)= x⊕y 对应的K桶
  - 若y已在于该K 桶中，把对应项移到该K 桶的尾部
  - 若y不在该K 桶中
    - 若该K 桶不满k，把y的三元组插入队列尾部
    - 若该K 桶满k，向头节点z （最老）发RPC_PING
      - 如果z 没有响应，则从K 桶中移除z 的信息，并把y 的信息插入队列尾部
      - 如果z 有响应，则把z 的信息移到队列尾部，同时忽略y 的信息。
  - 若某bucket过去1小时内没有任何的node lookup操作
    - 则这个node就随机搜索一个在该bucket覆盖范围内的id
- 特点
  - 离自己越近的节点越容易放在K桶中，越远越欠了解
  - 在线时间长的节点具有较高的可性继续保留在K桶中
  - 可以保持系统稳定和减少节点进出的路由维护代价
  - 若某节点长时间在线，则网络中有很多节点连接到该节点，其负载会随着在线时间的增大而增大，导致负载极不平衡

节点查找简述

- K桶中节点的选择
  - 离自己异或距离越近的结点越容易被选到联系人列表里
    - 了解自己越近的节点，越远越欠了解，类似交朋友
  - 联系人列表更改
    - 不在线的联系人将被删除，被新找到的联系人所代替
    - 要查找某个结点y时，如果y不在我的联系人列表里，我就从联系人列表里找到与y距离最近的结点z，
      - 然后向z查询y．如果z认识y，就把y的信息告诉我；
      - 如果z也不认识y，z就从自己的联系人列表里找到与y距离更近的w，
    - 然后我向w查询y．这个递归过程不断重复，直到找到y为止
- 结点查找是进行信息存储和查询的基础.

节点查找（找目的节点的三元组）

- node lookup:
  - 找到给定距离的 ID 最近的 k 个 node，a:并发参数，比如3
  - Step1:从最近的 k-bucket 里面取出 a 个最近的 node，然后向这 a 个 node并行发送异步的 FIND_NODE RPC
  - Step2:发送 FIND_NODE RPC 给前一步返回的 node,不必等a 个 PRC 都返回后才开始
    - 从发送者已知的 k 个最接近目标的 node 当中，取出 a 个还没有查询的 node，向这 a 个 node 发送 FIND_NODE RPC
      - 没有迅速响应的 node 将考虑排除，直到其响应。
    - 若一轮 FIND_NODE RPC 没有返回一个比已知的所有 node 更接近目标ID，发送者将再向 k 个最接近目标的、还没有查询的 node 发送 FIND_NODE RPC。
  - Step3:查找结束的条件：发送者已经向 k 个最近的 node 发送了查询，并且也得到了响应。

节点查找步骤

- x要查找ID值为t的节点，Kad递归操作步骤：
  - 计算到t 的距离：d = d(x , t) = x ⊕ t
  - 从x的第[logd]个K桶中取出 α 个节点信息，执行FIND_NODE
    - 若该K 桶表项少于 α 个，则从附近多个桶中选择最接近d 的总共 α 个节点
  - 对受到查询的节点
    - 若自己是t，则回答自己是最是接近t的；
    - 否则测量自己和t的距离，并从自己对应的K桶中选择 α 个节点的信息给x
  - x对新接收到的每个节点
    - 再次执行FIND_NODE 操作，此过程不断重复执行，
    - 直到每一个分支都有节点响应自己是最接近t 的。
    - 没有迅速响应的节点将被迅速排除出候选列表，直到其响应。
  - 通过上述查找操作，x 得到了k 个最接近t 的节点信息
  - Kad一般取 α = 20

- 节点0011→节点1110 ?。
  - 计算距离 d = 0011⊕1110 = 1101 = 13
  - →自举节点101，它计算101x⊕1110=0100 = 4，查对应4的k桶内容有→1101节点；
  - 1101节点计算1101x⊕1110=0011 = 3，查对应3的k桶内容有→11110
  - 11110节点计算11110⊕1110x= 0010 = 2，查对应2的k桶命中→1110

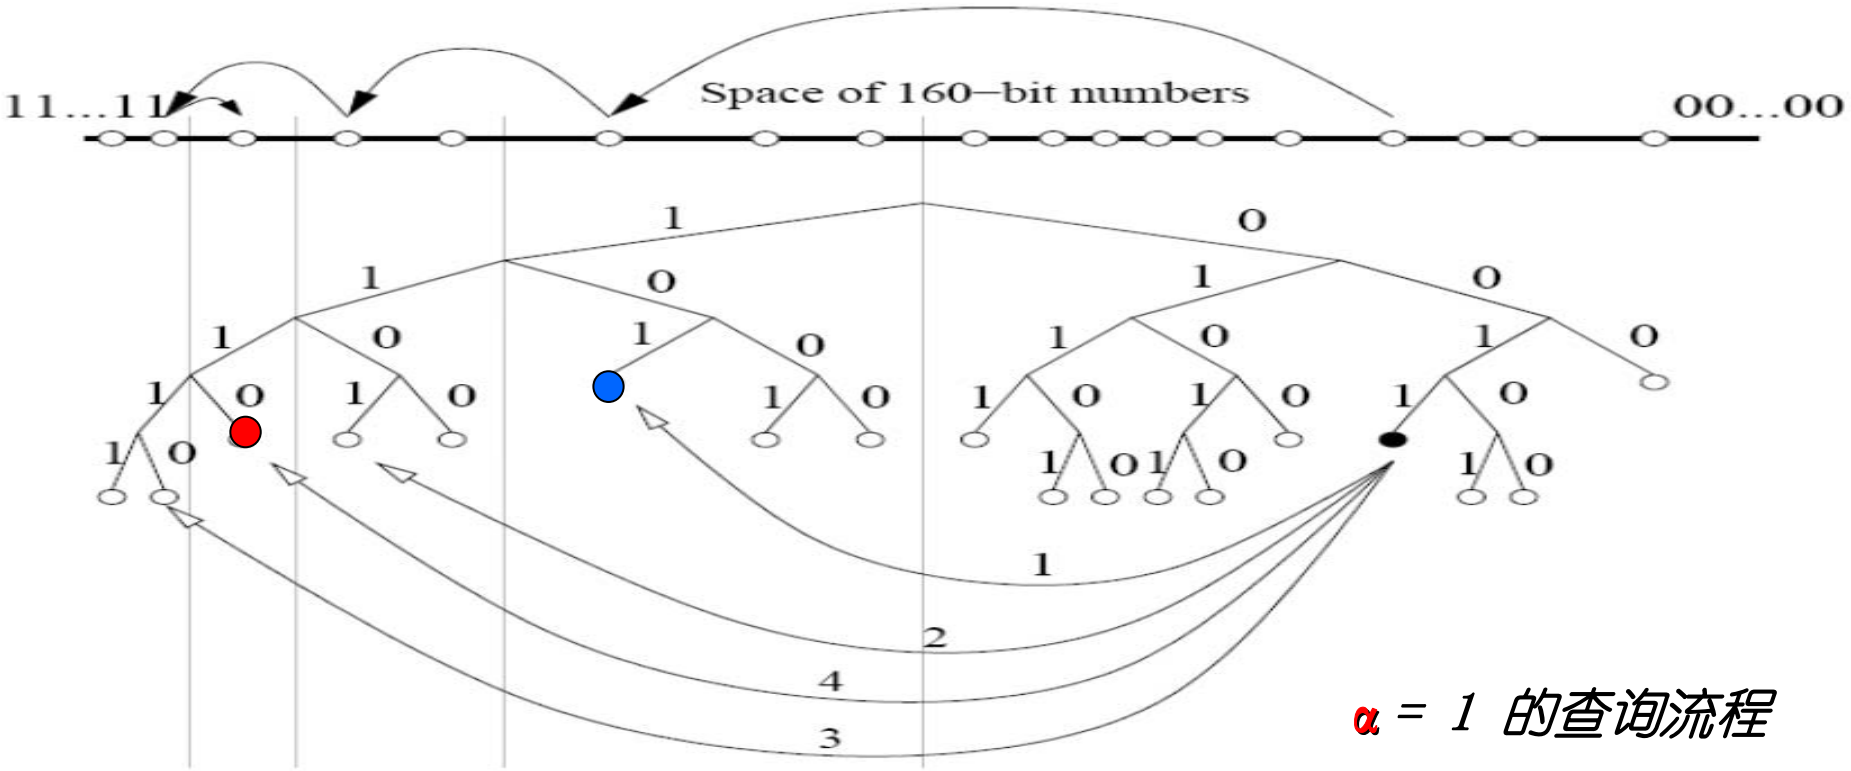

α = 1 的查询流程

数据的存储

- 存储<Key, Value>对的步骤：
  - 用node lookup算法，找到距离 Key 最近的 k 个 nodes
  - 向这 k 个 nodess 发送 STORE RPC
  - 必要时,每个 node重新发布(re-publish)所有的 <Key,Value>
- 更新要求：
  - <Key,Value>的原始发布者每隔24小时重新发布一次
  - 否则<Key,Value>将在发布之后的24小时（某些应用更长）之后过期
- 发布与搜寻的一致性
  - 当节点w 发现新节点u比w 上更接近，则w把自己的<key,value>对数据复制到u 上，但是并不会从w 上删除

文件查找

- 节点x 查询<key,value>对，和查找节点操作类似
- x选择k个最接近key值的节点ID，执行FIND_VALUE 操作
  - 对每个返回的新节点重复执行FIND_VALUE 操作，直到某个节点返回value 值。
  - 一旦FIND_VALUE 操作成功执行，则<key,value>对数据会缓存在没有返回value 值的最接近的节点上。
- 这对下次查询相同key ，会有加速效果。于是热门<key,value>对数据的缓存范围就逐步扩大，使系统具有更好响应速度

节点数据的有效性保障

- 节点有效性
  - 利用流经自己的节点查询操作，持续更新对应的K 桶信息
  - 对过去一个小时内还没收到任何节点查询操作的K 桶执行刷新操作---BT 协议实现规定为15 分钟。
  - 刷新操作：从该K 桶中随机选择一节点执行一次FIND_NODE操作
- 数据有效性
  - 特点：节点离开网络不发布任何信息（弹性网络特点或目标）
  - 要求：每个Kad 节点必须周期性的发布。本节点存放的全部<key ， value>数据对，并把这些数据缓存在自己的k 个最近邻居处，
  - 使失效节点上数据会被很快更新到其他新节点上。

4.4.7 结构化网络总结

- Chord/CAN/Tapestry/Pastry
- 目标相同
  - 减少路由到指定文件的P2P跳数
  - 减少每个Peer必须保持的路由状态
- 算法异同
  - 节点与对象Hash映射到**同一空间**，走“**最接近**”路由
  - 都保证算法的跳数与Peer群组的大小相关
  - 方法上的差别很小

P2P 算法的比较

P2P系统	不同P2P定位算法的比较标准					
	模式	参数	跳数	路由状态	进出Peers	可靠性
Napster	集中元数据索引/查S直接下载	无	常数	常数	常数	中心服务器返回多个下载位置,客户端可在下载
Gnutella	广播请求 直接下载	无	无保证	常数 (约3-7)	常数	接收多个可用数据的响应,可重试
Chord	单维/循环ID空间	N:群组的Peers数	LogN	LogN	$(LogN)^2$	所个顺序Peers重复数据,应用可重试
CAN	多维ID空间	d: 维数	$d*N^{1/d}$	2d	2d	多Peers响应,应用可重试
Tapestry	全局Mesh	b:所选标识符的基	Log_bN	Log_bN	LogN	重复数据在多个Peers上,保持多踪迹
Pastry	全局Mesh	b:所选标识符的基	Log_bN	$b*Log_bN+b$	LogN	重复数据在多个Peers上,保持多踪迹 多通路

- CAN和Chord
  - Can平面几何划分；Chord幂相邻关系
  - 缺点：P2P网络没有考虑物理网络距离
  - 信息共享
- Pastry
  - 直接定位对象
  - 缺点：研究不彻底
- Tapstry
  - Root冗余（优）、动态构建、对象复制
  - 缺点：softstate，路由失败，动态构建不彻底

优化性能的增强技术

- 复制(Replication)
  - 把对象/文件的拷贝放在请求Peers附近,最小化连接距离
  - 改变数据时必须保持数据拷贝的一致性
  - OceanStore基于冲突解的更新传播模式支持一致性语义
- 高缓(Cache)
  - 减少获取文件/对象路径的长度,进而Peers间交换消息数
  - 这一减少很有意义-Peers间通信时延是严重的性能瓶颈
  - Freenet:命中文件传播到请求者途中所有节点高缓它
  - 目标是最小化时延,最大化请求吞吐率,很少高缓大数据
- 智能路由和网络组织
  - 社交“小世界”现象,60年美， 明信片均6熟链找到生人
  - 局部搜索策略,代价与网络规模成子-线性增加
  - OceanStore/Pastry网络上积极移动数据提高性能

查询规模

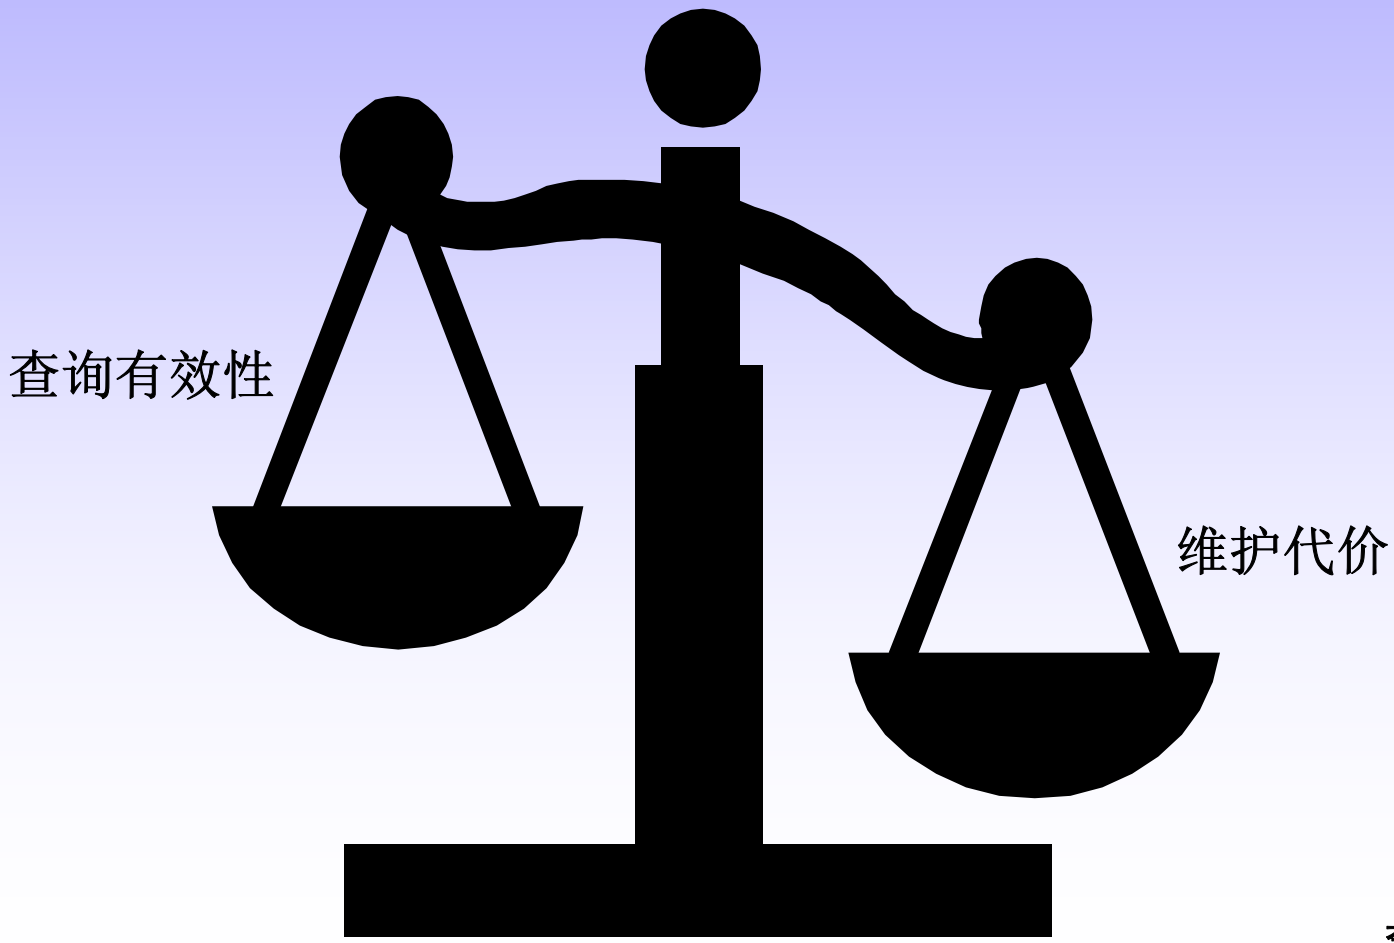

- 由于每个K桶覆盖距离的范围呈指数关系增长，这就形成了离自己近的节点的信息多，离自己远的节点的信息少，从而可以保证路由查询过程是收敛。也就是说，每个结点都对自己附近的情况非常了解，而随着距离的增大，了解的程度不断降低降低。
- 经过证明，对于一个有N 个节点的Kad 网络，最多只需要经过logN 步查询，就可以准确定位到目标节点。

DHT存在的问题和研究重点

- 解决P2P系统中固有的Churn高的现象，每个节点上下线都要O(LogN)的修复操作，研究方向：**增大邻接表，增加发布及搜索冗余。**
- 模糊查询的支持
  - OverNet的查询存在的问题：Key不能太多，切词准确性
  - 让DHT支持复杂查询，不按照NodeID组织DHT，而按照关键字来组织（这方面MSRA那边在作些尝试）
  - 其他办法2：用DHT维护拓扑，而资源的定位仍然采用广播方式查询;分级的索引
- 文件的本地存储特性的消失
  - 目录的结构信息（本地相同目录下两个相关文件可能被Hash到不同别的节点）
- DHT这种架构更容易受到攻击（研究重点）
  - 伪装节点
  - 拒绝转发消息等
- 不能吻合系统中节点的异质性(可能弱节点被分配到热门关键字)：**a）对热门关键字作Cache b)采用分层DHT结构如Kelips，包括以物理位置为依据的分层，以兴趣为依据的分层等**

P2P网络路由方式总结

- 服务器路由(Napster)；
- 洪泛路由(Gnutella)；
- 双层路由(KaZaA)；
- 数值邻近路由(Chord)；
- 逐位匹配路由(Tapestry)；
- 位置邻近路由(CAN),；
- 层次路由(Viceroy)；
- 混合式路由(Pastry)...

结论

- The key challenge of building wide area P2P systems is a scalable and robust location service
- Solutions covered in this course
  - Naptser: centralized location service
  - Gnutella: broadcast-based decentralized location service
  - Freenet: intelligent-routing decentralized solution (but correctness not guaranteed; queries for existing items may fail)
  - CAN, Chord, Tapestry, Pastry: intelligent-routing decentralized solution
    - Guarantee correctness
    - Tapestry (Pastry ?) provide efficient routing, but more complex