

计算智能讲义——MaxSAT 问题

计算机科学与技术学院 M201973122 李研

1 Definition

首先给出以下符号定义：

Symbol	Definition	Description
x_i	<i>Variable</i>	变元, $x_i + \bar{x}_i = 1, i = 1, 2, \dots, n$
C_i	<i>Clause</i>	子句, $C_i = \left(\bigvee_{i \in S_i^+} x_i \right) \vee \left(\bigvee_{i \in S_i^-} \bar{x}_i \right), i = 1, 2, \dots, m$
CNF	<i>Formula</i>	合取范式, $CNF = \bigwedge_{i \in S} C_i, i = 1, 2, \dots, n$

Maximum Satisfiability: 找到一组 x_i 的取值, 使得满足的子句数目 $|C_i|$ 最大。

2 Algorithms

给出以下符号定义：

Symbol	Definition	Description
$E[Z_i]$	<i>Expectation</i>	期望, 对应字句 C_i 被满足的期望
$E[Z x_i]$	<i>Conditional Expectation</i>	条件期望, 在 x_i 确定取值的前提下, CNF 被满足的期望
$E[Z]$	<i>Total Expectation</i>	总期望, CNF 被满足的期望

2.1 Randomized Algorithm

- 算法描述:

将 x_i 分别以 $\frac{1}{2}$ 的概率设置为 0 或 1, 则 C_i 被满足的期望为 $E[Z_i] = 1 - 2^{-|C_i|}$,

CNF 被满足的期望为 $E[Z] = \sum_{i=1}^m E[Z_i] = \sum_{i=1}^m (1 - 2^{-|C_i|})$ 。

- 近似比分析：

设 $\min |C_i| = K$ ，则有

$$m(1 - 2^{-K}) \leq E[Z] \leq OPT \leq m$$

- 算法分析：

- ✧ 简单粗暴，易于理解；

- ✧ 结果不可控，近似比只是给出理论上期望的上界，而未必每次都能得到相应质量的解。

2.2 Derandomized Algorithm

- 算法描述：

在算法①的基础上，每个变元 x_i 都有 $\frac{1}{2}$ 的概率取 0 或 1，即有

$$E[Z] = \frac{1}{2} E[Z | x_i = 1] + \frac{1}{2} E[Z | x_i = 0]。对于每个变元 x_i ，比较 $\frac{1}{2} E[Z | x_i = 1]$$$

和 $\frac{1}{2} E[Z | x_i = 0]$ 的大小，选择二者中期望值较大者对应的 x_i 取值。在此基础上，进行下一步迭代。

- 近似比分析：

因为每一步迭代都选择了期望值较大的，所以总的条件期望 $E[Z | x]$ 要大于

随机算法的期望值 $E[Z]$ ：

$$E[Z | x] \geq E[Z] \geq m(1 - 2^{-K})$$

- 算法分析：

- ✧ 结果可控，在变元顺序确定的情况下能保证结果一致性；

- ✧ 结果与变元顺序有关，没有回溯，变元的值一旦确定便不能再更改；

- ✧ 算法复杂度较高，条件期望的计算比较耗时；

- ✧ 可能的优化方向：使用 *branch-and-bound* 的树搜索框架，通过维护一个全局的条件期望实现剪枝和加速搜索。

2.3 LP Rounding Algorithm

给出以下两个决策变量的定义：

Symbol	Definition	Description
y_i	<i>Decision Variables</i>	决策变量，变元 x_i 的 0/1 决策变量
q_i	<i>Decision Variables</i>	决策变量，子句 C_i 的 0/1 决策变量

- 算法描述:

建立 MaxSAT 混合整数规划模型如下:

$$\begin{aligned} & \text{maximize: } \sum_{i=1}^m q_i \\ & \text{s.t. } q_i \leq \sum_{j \in S_i^+} y_j + \sum_{j \in S_i^-} (1 - y_j) \quad \forall i \\ & q_i, y_j \in \{0, 1\} \end{aligned}$$

- ◇ Relaxing:

松弛最后一条布尔约束为 $0 \leq q_i, y_j \leq 1$, 即得到线性规划模型。

- ◇ Rounding:

求解模型, 并按照下述策略设置变元取值:

for $j = 1$ to n do

$$\text{Independently set } x_j = \begin{cases} 1: & \text{with probability } y_j^* \\ 0: & \text{with probability } 1 - y_j^* \end{cases}$$

end for

- 近似比分析:

以 $C_1 = x_1 \vee \dots \vee x_k$ 为例, 利用算数-几何平均不等式, 得到 C_1 的部分期望如下:

$$\begin{aligned} \Pr[C_1] &= 1 - \prod_{j=1}^k (1 - y_j^*) \\ &\geq 1 - \left(\frac{1}{k} \sum_{j=1}^k (1 - y_j^*) \right)^k \\ &\geq 1 - \left(1 - \frac{q_1^*}{k} \right)^k \\ &\geq 1 - \left(1 - \frac{1}{k} \right)^k \\ &\geq q_1 \left(1 - \left(1 - \frac{1}{k} \right)^k \right) \\ &\geq q_1 (1 - 1/e) \end{aligned}$$

$$\text{则 } E[Z] = \sum_{i=1}^m E[Z_i] \geq \sum_{i=1}^m \left(1 - \left(1 - \frac{1}{|C_i|} \right)^{|C_i|} \right) \geq m \left(1 - \left(1 - \frac{1}{K} \right)^K \right).$$

- 算法分析:

- ◇ 结果相对可控, 较算法①求解质量有较大提升;

- ◇ 求解效率与线性规划求解器的性能有较大关系, 随着变元数目增多, 求解时间也逐渐延长。

2.4 LP Derandomized Algorithm

- 算法描述:

在算法③的基础上去随机化, 每个变元 x_i 都有 y_i^* 的概率取 1, $1 - y_i^*$ 的概率取 0, 即 $E[Z] = y_i^* \cdot E[Z | x_i = 1] + (1 - y_i^*) \cdot E[Z | x_i = 0]$ 。对于每个变元 x_i , 比较 $y_i^* \cdot E[Z | x_i = 1]$ 和 $(1 - y_i^*) \cdot E[Z | x_i = 0]$ 的大小, 选择二者中较大的期望值, 取其对应的 x_i 取值。在此基础上, 进行下一步迭代。

- 近似比分析:

同理, 该算法的条件期望 $E[Z | x]$ 要大于算法③的期望值 $E[Z]$:

$$E[Z | x] \geq E[Z] \geq m \left(1 - \left(1 - \frac{1}{K} \right)^K \right)$$

- 算法分析:

- ◇ 结果可控, 且与变元顺序无关;
- ◇ 继承了算法②③的优缺点, 既是四类算法中求解质量最好的, 也是耗时最多的;
- ◇ 可能的优化方向: 将算法②和算法④结合可以给出一个 $\frac{3}{4}$ 近似比的算法 (每次从两个算法中随机挑选一个执行):

$$E[Z] = \sum_{i=1}^m E[Z_i] \geq \sum_{i=1}^m \frac{1}{2} \left(\left(1 - 2^{-|C_i|} \right) + \left(1 - \left(1 - \frac{1}{|C_i|} \right)^{|C_i|} \right) \right) \geq (3/4)m$$

3 Implementation

Github: <https://github.com/lyandut/MyMaXSat>